

**PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO
PÓS-GRADUAÇÃO EM CIÊNCIA DE DADOS E ANALYTICS**

BÁRBARA JAEGER SPECIAN

OMNISALES SERVICE INTELLIGENCE LAKEHOUSE: PIPELINE MEDALLION

**CURITIBA
2026**

BÁRBARA JAEGER SPECIAN

OMNISALES SERVICE INTELLIGENCE LAKEHOUSE: PIPELINE MEDALLION

MVP (*Minimum Viable Product* – Produto Mínimo Viável) apresentado ao módulo de Engenharia de Dados do Programa de Pós-Graduação em Ciência de dados e Analytics da Pontifícia Universidade Católica do Rio de Janeiro como requisito parcial para a obtenção de título de Especialista em Ciência de Dados.

Orientador: Prof. Dr. Victor Almeida.

**CURITIBA
2026**

BÁRBARA JAEGER SPECIAN

OMNISALES SERVICE INTELLIGENCE LAKEHOUSE: PIPELINE MEDALLION

MVP (Minimum Viable Product – Produto Mínimo Viável) apresentado ao módulo de Engenharia de Dados do Programa de Pós-Graduação em Ciência de dados e Analytics da Pontifícia Universidade Católica do Rio de Janeiro como requisito parcial para a obtenção de título de Especialista em Ciência de Dados.

Aprovado em: _____ de _____ de 2026.

BANCA EXAMINADORA

Prof. Dr. Victor Almeida – Orientador

PUC-Rio

Prof. Me. Iury Rosal

PUC-Rio

Prof. Me. Silvio Alonso

PUC-Rio

RESUMO

Em um marketplace, informações sobre pedidos, itens, pagamentos, frete, sellers, entregas e avaliações estão distribuídas entre diferentes tabelas, dificultando a análise conjunta do desempenho comercial e da qualidade do serviço. Para enfrentar essa fragmentação, este MVP desenvolveu, no Databricks, um Lakehouse com validação inicial dos arquivos, ingestão na camada Bronze, tratamento e quarentena de registros inválidos na Silver, modelagem analítica na Gold e controles de qualidade e governança. Um Job orquestrou a execução sequencial de Bronze, Silver, Gold e qualidade, enquanto consultas analíticas responderam a cinco perguntas sobre concentração de vendas, confiabilidade logística, atrasos, distância, frete e satisfação. O resultado foi uma base rastreável e reproduzível que permite identificar segmentos de maior relevância comercial associados a riscos de entrega e pior experiência do cliente, respeitadas as limitações dos dados históricos utilizados.

Palavras-chave: Engenharia de Dados; Lakehouse; Arquitetura Medallion; Qualidade de Dados; Logística de Marketplace.

ABSTRACT

In a marketplace, information about orders, items, payments, freight, sellers, deliveries, and reviews is spread across different tables, making it difficult to analyze commercial performance and service quality together. To address this fragmentation, this MVP developed a Lakehouse in Databricks, beginning with input-file validation, followed by ingestion into the Bronze layer, data cleaning and quarantine of invalid records in Silver, analytical modeling in Gold, and data quality and governance controls. A Job orchestrated the sequential execution of Bronze, Silver, Gold, and quality checks, while analytical queries answered five questions about sales concentration, logistics reliability, delays, distance, freight, and customer satisfaction. The result was a traceable and reproducible data foundation for identifying commercially relevant segments associated with delivery risks and a poorer customer experience, within the limitations of the historical data used.

Keywords: Data Engineering; Lakehouse; Medallion Architecture; Data Quality; Marketplace Logistics.

SUMÁRIO

1. CONTEXTO.....	8
1.1 PROBLEMA DE NEGÓCIO	8
1.2 OBJETIVOS	10
1.2.1 Objetivo geral	10
1.2.2 Objetivos específicos	10
2. DESENVOLVIMENTO	11
2.1 FONTE DE DADOS.....	11
2.1.1 Delimitação ética e técnica	13
2.1.2 Estrutura dos arquivos	13
2.1.3 Atributos que sustentam a análise logística	15
2.1.4 Limitações do dataset.....	17
2.2 CARGA DOS DADOS.....	18
2.3 CAMADA BRONZE.....	21
2.4 CAMADA SILVER	24
2.5 CAMADA GOLD	29
2.6 GOVERNANÇA, SEGURANÇA E RASTREABILIDADE	32
2.7 QUALIDADE DOS DADOS	39
2.8 PIPELINE	46
2.9 ANÁLISE DE DADOS	47
2.9.1 Pergunta 1 — Concentração comercial	48
2.9.2 Pergunta 2 — Desempenho logístico.....	52
2.9.3 Pergunta 3 — Relação entre atraso e satisfação	58
2.9.4 Pergunta 4 — Distância, frete e logística	60
2.9.5 Pergunta 5 — Priorização de sellers e categorias	62
2.10 LIMITAÇÕES DO PIPELINE	67
2.11 PRINCIPAIS APRENDIZADOS.....	69
2.12 AUTOAVALIAÇÃO	70
3. CONCLUSÃO.....	71
REFERÊNCIAS	73

LISTA DE TABELAS

TABELA 01 – Perguntas de negócio a serem respondidas.....	09
TABELA 02 – Descrição da fonte de dados.....	12
TABELA 03 – Estrutura do dataset.....	14
TABELA 04 – Principais atributos para análise logística.....	15
TABELA 05 - Dimensões de qualidade de dados.....	40

LISTA DE IMAGENS

IMAGEM 01 — Ambiente Databricks Free Edition.....	18
IMAGEM 02 — Landing zone do Lakehouse no Databrick.....	19
IMAGEM 03 — Execução do notebook de validação da landing zone.....	20
IMAGEM 04 — Validação pós-carga do notebook 02_ingestao_bronze.....	22
IMAGEM 05 — Tabelas Delta persistidas no schema bronze.....	23
IMAGEM 06 — Execução completa e aprovada do notebook 03_transformacao_silver.....	27
IMAGEM 07 — Tabelas Silver tratadas, validadas e enriquecidas disponíveis.....	28
IMAGEM 08 — Tabelas Gold dimensionais, fatos e marts analíticos persistidos.....	30
IMAGEM 09 — Validação automatizada do notebook 04_modelagem_gold.....	32
IMAGEM 10 — Execução do notebook 07_governanca_catalogo.....	33
IMAGEM 11 — Resultado da validação de cobertura do catálogo de dados.....	36
IMAGEM 12 — Exemplo de linhagem de dados no Unity Catalog.....	39
IMAGEM 13 — Comparação entre registros Bronze, registros Silver e quarentena.....	43
IMAGEM 14 — Resumo final das validações de qualidade.....	45
IMAGEM 15 — Execução orquestrada do pipeline OmniSales no Databricks Jobs.....	46
IMAGEM 16 — Top 5 categorias por GMV.....	49
IMAGEM 17 — Top 5 sellers.....	51
IMAGEM 18 — Top 5 estados de cliente.....	52
IMAGEM 19 — Top 5 estados por desempenho.....	54
IMAGEM 20 — Top 5 categorias por desempenho.....	56
IMAGEM 21 — Top 5 sellers por desempenho.....	58
IMAGEM 22 — Comparação entre pedidos entregues no prazo e com atraso.....	60
IMAGEM 23 — Evolução do frete médio e do prazo médio de entrega por faixa de distância aproximada entre seller e cliente.....	62
IMAGEM 24 — Top 5 sellers prioritários.....	65
IMAGEM 25 — Top 5 categorias prioritárias.....	67

1. CONTEXTO

O varejo atual não funciona mais como uma operação separada entre loja física, website, aplicativo e marketplace. Um mesmo cliente pode pesquisar um produto no aplicativo, comparar preço no site, concluir a compra em um marketplace e receber o pedido em casa.

Nesse cenário, a venda não termina no pagamento: a experiência percebida pelo cliente depende do prazo prometido, da qualidade da entrega, do custo do frete e da capacidade do vendedor de cumprir o serviço contratado. Para a empresa, isso gera múltiplas fontes de dados, como pedidos, itens vendidos, pagamentos, clientes, vendedores, categorias, frete, status de entrega, localização e avaliações.

O desafio não é apenas ter dados; é consolidá-los e transformá-los em informação confiável para decisões comerciais e operacionais. Em muitas empresas, pedidos, pagamentos, dados de clientes, vendedores, transportadoras, entregas e avaliações permanecem em sistemas isolados, planilhas, plataformas de e-commerce, ERPs, aplicativos e parceiros logísticos.

Como consequência, a empresa não consegue relacionar de maneira confiável faturamento, frete, prazo de entrega, atraso e satisfação. Isso produz indicadores inconsistentes, demora para identificar falhas de serviço e dificulta o rastreamento de como cada métrica foi calculada.

Dados integrados permitem transformar a jornada de compra em decisões operacionais. Com uma camada Gold bem modelada, gestores conseguem identificar sellers (vendedores) com alta receita, mas baixo nível de serviço; categorias com atraso recorrente; regiões com forte demanda e baixa eficiência logística; e perfis de pedido associados à insatisfação do cliente. Dessa forma, o Lakehouse deixa de ser somente uma estrutura técnica e passa a apoiar decisões de receita, retenção e qualidade de serviço.

1.1 PROBLEMA DE NEGÓCIO

Uma empresa de marketplace e varejo digital possui dados detalhados sobre vendas, clientes, pagamentos, produtos, vendedores, frete, entrega e avaliações. Entretanto, essas informações estão distribuídas em tabelas operacionais e não estão

disponíveis em uma estrutura única, padronizada e pronta para análise. Como resultado, a empresa consegue acompanhar pedidos e faturamento, mas tem dificuldade para compreender se o crescimento comercial é acompanhado por uma operação logística confiável e uma experiência satisfatória para o cliente.

Sem integração e regras de qualidade, a empresa não consegue responder com segurança quais sellers, categorias ou regiões combinam alta receita com baixo desempenho logístico; onde atrasos são mais frequentes; se custos de frete elevados estão associados a avaliações negativas; ou em quais períodos há degradação operacional.

O Lakehouse resolverá essa fragmentação por meio de tabelas analíticas padronizadas, documentadas e rastreáveis, permitindo que vendas, entrega e satisfação sejam analisadas em conjunto. As perguntas abaixo serão o contrato analítico do MVP. Cada uma será respondida com consultas SQL e/ou visualizações em cima da camada Gold.

TABELA 01 – Perguntas de negócio a serem respondidas

Pergunta de negócio	Decisão apoiada
Quais categorias, sellers e estados concentram maior número de pedidos, receita de produtos, valor de frete e ticket médio?	Priorização comercial, cobertura regional e gestão de sellers
Qual é a taxa de entrega no prazo, o atraso médio e o prazo médio de entrega por seller, categoria e estado do cliente?	Gestão de SLA, negociação com sellers e priorização operacional
Pedidos entregues após a data estimada apresentam avaliações piores do que pedidos entregues no prazo?	Gestão de experiência do cliente e ações de prevenção de churn
Como a distância aproximada entre seller e cliente se relaciona com prazo de entrega, atraso e valor de frete?	Estratégia de cobertura logística, localização de estoque e definição de promessa de entrega

Quais sellers ou categorias combinam alta receita com baixa confiabilidade logística e baixa satisfação?	Priorização de risco operacional e gestão de parceiros
--	--

Fonte: A autora (2026).

1.2 OBJETIVOS

O MVP propõe construir uma plataforma de dados em formato Lakehouse, utilizando o Databricks Free Edition e a arquitetura Medallion, para integrar dados de vendas e serviço pós-venda. O objetivo é disponibilizar uma visão analítica confiável no ciclo de vendas digitais e marketplace, da compra ao pós-venda: pedido → item → pagamento → expedição → entrega → avaliação. A análise priorizará a relação entre desempenho comercial e confiabilidade logística, avaliando como prazo, atraso, frete, distância aproximada, categoria, seller e localização se associam à satisfação do cliente.

1.2.1 Objetivo geral

Construir um pipeline de dados reprodutível, documentado e orientado à tomada de decisão no Databricks Free Edition, utilizando a arquitetura Medallion, para integrar dados de vendas de um marketplace brasileiro e analisar a relação entre desempenho comercial, confiabilidade logística e satisfação do cliente.

O pipeline deverá transformar dados brutos de pedidos, itens, pagamentos, clientes, produtos, sellers, entregas, geolocalização e avaliações em tabelas analíticas confiáveis, capazes de apoiar a identificação de atrasos, prazos de entrega, custos de frete, riscos operacionais e oportunidades de melhoria na experiência pós-venda.

Na camada Bronze, após ingestão dos dados, os arquivos operacionais serão preservados em seu formato bruto. Na camada Silver, os registros serão limpos, padronizados, tipados e validados. Na camada Gold, os dados serão organizados em um modelo dimensional, com tabelas fato e dimensões voltadas à análise de receita, clientes, produtos, logística, pagamentos e avaliações.

1.2.2 Objetivos específicos

Coletar e ingerir arquivos transacionais brutos de pedidos, itens, pagamentos, clientes, produtos, sellers, avaliações e geolocalização na camada Bronze.

Limpar, padronizar, tipar, deduplicar e validar os dados na camada Silver, aplicando controles de completude, consistência, unicidade, acurácia e integridade referencial.

Preservar registros inválidos ou incompletos em tabelas de quarentena para garantir rastreabilidade das exceções.

Calcular métricas comerciais e logísticas, incluindo receita, GMV, ticket médio, prazo de entrega, atraso, entrega no prazo, frete e índice frete/preço.

Estimar a distância aproximada entre seller e cliente usando geolocalização agregada por prefixo de CEP.

Modelar a camada Gold em esquema estrela, com tabelas fato de itens de venda e pedidos de serviço, além de dimensões de tempo, cliente, produto, categoria, seller e localidade.

Criar marts analíticos que permitam analisar desempenho de vendas, nível de serviço, satisfação, regiões, categorias e sellers.

Avaliar associações entre atraso, prazo, frete, distância aproximada e avaliações de clientes.

Identificar sellers, categorias e regiões que combinam alta relevância comercial com maior risco logístico.

Documentar a fonte, licença, arquitetura, catálogo de dados, regras de transformação, testes de qualidade, análises e evidências de execução no PDF e no repositório GitHub.

2. DESENVOLVIMENTO

2.1 FONTE DE DADOS

Para transformar os objetivos do MVP em uma solução verificável, foi necessário selecionar uma base que representasse a jornada do pedido, da compra à avaliação. O conjunto de dados da Olist foi escolhido por reunir informações de

vendas, pagamentos, frete, localização, entregas e avaliações, permitindo desenvolver e testar a pipeline proposta.

TABELA 02 – Descrição da fonte de dados

Item	Definição
Nome	Brazilian E-Commerce Public Dataset by Olist
Fonte original	Kaggle — Olist Brazilian E-Commerce
Autor/provedor	Olist, com referência de autoria atribuída a Olist e André Sionek
Período histórico	Pedidos de 2016 a 2018
Cobertura	Múltiplos marketplaces no Brasil
Volume	Aproximadamente 100 mil pedidos
Formato	Arquivos CSV relacionais
Granularidade principal	Pedido, item de pedido, pagamento, avaliação, cliente, produto e vendedor
Natureza	Dados comerciais reais, anonimizados
Canal inicial	Marketplace/e-commerce
Uso no MVP	Acadêmico, não comercial, com atribuição da fonte e respeito à licença
Licença de uso	CC BY-NC-SA 4.0 — Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International
Fonte (URL)	https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

Fonte: Kaggle (2026).

Este dataset será utilizado para construir um Lakehouse de vendas orientado à confiabilidade logística e à satisfação do cliente, integrando a jornada do pedido desde a compra até a entrega e a avaliação.

A base Olist é adequada ao problema de negócio definido porque permite integrar informações comerciais e operacionais que normalmente estão distribuídas em sistemas distintos de um marketplace: pedidos, itens, pagamentos, produtos, sellers, clientes, frete, entrega, localização e avaliações.

O diferencial deste MVP não será apenas identificar produtos ou categorias com maior receita. O foco será compreender se a qualidade logística acompanha o desempenho comercial e quais fatores estão associados a riscos de insatisfação do cliente. Para isso, a base fornece informações essenciais: data de compra, data de aprovação, data de entrega à transportadora, data real de entrega ao cliente, data estimada de entrega, valor do frete, preço do item, localização aproximada de cliente e seller, seller responsável e nota de avaliação.

2.1.1 Delimitação ética e técnica

A base de dados deste MVP utilizará dados públicos e anonimizados de um marketplace brasileiro. Não serão usados nome, CPF, e-mail, cartão, endereço completo ou qualquer identificador pessoal direto. Embora a fonte inicial represente predominantemente vendas digitais, o modelo será estruturado com o atributo de canal de venda, permitindo evolução futura para integração de vendas presenciais, website próprio e aplicativo.

As coordenadas de geolocalização serão usadas apenas após agregação por prefixo de CEP e exclusivamente para estimar distâncias em nível analítico. O MVP não exibirá endereços, não tentará identificar indivíduos ou sellers e não realizará análises em nível de residência. Essa decisão reduz riscos de privacidade e preserva o uso acadêmico responsável da base.

Embora a base Olist seja amplamente utilizada em projetos de análise de dados, este MVP não reproduz análises, notebooks ou arquiteturas já existentes. O projeto adota um problema de negócio próprio (confiabilidade do serviço de entrega e risco de insatisfação) e implementa uma modelagem, regras de qualidade, métricas de serviço, camada de quarentena e consultas analíticas originais. A Olist é utilizada exclusivamente como fonte pública de dados transacionais anonimizados.

2.1.2 Estrutura dos arquivos

A base contém nove CSVs principais. O nome dos arquivos será preservado na Bronze para favorecer rastreabilidade com a origem.

TABELA 03 – Estrutura do dataset

Arquivo bruto	Entidade	Granularidade	Chave principal	Relações principais
olist_orders_dataset.csv	Pedidos	Uma linha por pedido	order_id	Liga-se a clientes, itens, pagamentos e avaliações
olist_order_items_dataset.csv	Itens do pedido	Uma linha por item do pedido	order_id + order_item_id	Liga-se a produtos e vendedores
olist_order_payments_dataset.csv	Pagamentos	Uma linha por pagamento/ parcela de um pedido	order_id + payment_sequential	Liga-se a pedidos
olist_order_reviews_dataset.csv	Avaliações	Uma linha por avaliação	review_id	Liga-se a pedidos
olist_customers_dataset.csv	Clientes	Uma linha por entidade de cliente no pedido	customer_id	Liga-se a pedidos e ao identificador persistente customer_unique_id
olist_products_dataset.csv	Produtos	Uma linha por produto	product_id	Liga-se a itens de pedido
olist_sellers_dataset.csv	Vendedores	Uma linha por vendedor	seller_id	Liga-se a itens de pedido

olist_geolocation_dataset.csv	Geolocalização	Múltiplas linhas por prefixo de CEP	Não é única; usar agregação na Silver	Liga-se a cliente e vendedor pelo prefixo de CEP
product_category_name_translation.csv	Tradução de categoria	Uma linha por categoria	product_category_name	Liga-se a produtos

Fonte: Kaggle (2026).

A base foi intencionalmente dividida em múltiplos datasets para organização e entendimento das entidades; o conjunto permite observar um pedido por diversas perspectivas, como status, preço, pagamentos, frete, localização, atributos de produto e avaliações.

Vale a pena comentar que existem duas regras fundamentais que devem ser consideradas nestes dados:

- Um pedido pode ter vários itens, e os itens de um mesmo pedido podem ser atendidos por vendedores distintos.
- Um pedido pode ter mais de um registro de pagamento; portanto, juntar itens e pagamentos diretamente por order_id sem agregação prévia multiplica registros e distorce métricas financeiras.

Ambas são características explicitamente destacadas pela documentação do dataset e serão tratadas como controles de qualidade e modelagem do MVP.

2.1.3 Atributos que sustentam a análise logística

A análise de confiabilidade logística será construída a partir da integração entre tabelas de pedidos, itens, clientes, sellers, avaliações e geolocalização. Os principais atributos sustentadores dessa análise estão destacados a seguir.

TABELA 04 – Principais atributos para análise logística

Indicador ou atributo	Campos de origem	Regra prevista
Data de compra	orders.order_purchase_timestamp	Marco inicial da jornada do pedido
Data real de entrega	orders.order_delivered_customer_date	Marco final da entrega ao cliente
Data estimada de entrega	orders.order_estimated_delivery_date	Base para avaliar cumprimento de promessa
Prazo real de entrega	Datas de compra e entrega	Diferença entre entrega real e compra
Status de atraso	Datas real e estimada	Atrasado quando entrega real for posterior à data estimada
Dias de atraso	Datas real e estimada	Diferença positiva entre entrega real e estimada
Valor do frete	order_items.freight_value	Soma por pedido e média por item/categoria/seller
Preço do produto	order_items.price	Receita de produto e base para índice frete/preço
Seller responsável	order_items.seller_id	Análise de desempenho e risco operacional
Localização do cliente	customers.customer_zip_code_prefix	Destino para análise regional e distância aproximada

Localização do seller	sellers.seller_zip_code_prefix	Origem para análise regional e distância aproximada
Distância aproximada	Latitude/longitude agregadas por CEP	Distância geográfica calculada em nível agregado
Satisfação	reviews.review_score	Nota de 1 a 5 associada à experiência do pedido
Categoria	products.product_category_name	Segmentação de desempenho comercial e logístico

Fonte: A autora (2026).

2.1.4 Limitações do dataset

O dataset é histórico, cobrindo 2016 a 2018; ele não descreve diretamente comportamento comercial de 2026. O canal de compra não é segmentado de forma explícita entre website, app ou loja física. O escopo inicial é marketplace/e-commerce.

Além disso, não há custo de aquisição, custo de produto, margem real ou lucro líquido; portanto, analisaremos receita/GMV, e não margem. Os valores de pagamento podem divergir de preço + frete em razão de vouchers, múltiplas modalidades de pagamento, arredondamentos ou regras operacionais. Essa reconciliação será uma verificação de qualidade, não uma suposição.

As avaliações nem sempre contêm comentário textual e podem ter nulos; o MVP analisará primeiramente a nota numérica. A geolocalização por CEP é aproximada e não deve ser usada para inferir endereço individual ou localização exata de pessoas.

Ainda, o customer_id representa o registro associado a um pedido, enquanto customer_unique_id é a chave apropriada para medir recorrência de um mesmo cliente anonimizado.

A base não disponibiliza uma transportadora identificada por pedido; portanto, o desempenho será analisado por seller, categoria, região e período, não por transportadora. A data de entrega à transportadora não representa necessariamente o instante de coleta física nem permite medir todas as etapas internas da cadeia logística.


Avaliações podem refletir múltiplos aspectos da experiência de compra, como produto, entrega, expectativa ou atendimento. Assim, notas menores serão analisadas como associadas a fatores logísticos, e não como prova de que a logística foi a única causa.

2.2 CARGA DOS DADOS

A coleta dos dados foi realizada a partir da fonte oficial Brazilian E-Commerce Public Dataset by Olist, disponibilizada publicamente na plataforma Kaggle. O conjunto foi obtido por download manual do arquivo compactado disponibilizado pela fonte, seguido da extração local de seus nove arquivos no formato CSV. A estratégia de download manual foi escolhida por se tratar de um dataset público, histórico, estático e de dimensão compatível com a implementação acadêmica no Databricks Free Edition.

Os arquivos obtidos foram preservados com seus nomes originais e sem alteração de conteúdo antes da carga na nuvem. Foram considerados obrigatórios os arquivos referentes a pedidos, itens de pedido, pagamentos, avaliações, clientes, produtos, sellers, geolocalização e tradução de categorias. A preservação da estrutura original é importante para garantir rastreabilidade entre a fonte e as transformações posteriores, permitindo identificar a origem de cada entidade utilizada no pipeline.


IMAGEM 01 — Ambiente Databricks Free Edition



Fonte: A autora (2026).

Após acessar o Databricks Free Edition, demonstrado acima, seguiu-se para o armazenamento em nuvem, sendo criado o catálogo `main_catalog` no Unity Catalog do Databricks. Dentro desse catálogo, foram estruturados os schemas `bronze`, `silver` e `gold`, que representam as camadas da arquitetura Medallion adotada no projeto, conforme Imagem 02.

IMAGEM 02 — Landing zone do Lakehouse no Databrick



Fonte: A autora (2026).

A camada Bronze foi destinada ao armazenamento de dados de origem e às tabelas brutas; a Silver será utilizada para dados limpos, padronizados e validados; e a Gold armazenará as tabelas fato, dimensões e marts analíticos orientados à análise de vendas, confiabilidade logística e satisfação do cliente.


Como landing zone, foi criado o Unity Catalog Volume `main_catalog.bronze.olist_raw`. Os nove arquivos CSV foram enviados simultaneamente para esse Volume pela interface do Databricks. O caminho lógico

adotado para acesso aos arquivos no pipeline é: `‘/Volumes/main_catalog/bronze/olist_raw/’`.

Após a carga, foi implementado o notebook `01_validacao_landing_zone`, responsável por verificar programaticamente a disponibilidade dos arquivos obrigatórios no caminho definido.

O notebook compara a lista de arquivos encontrados no Volume com a relação esperada de nove CSVs e interrompe a execução caso qualquer arquivo esteja ausente. A validação foi concluída com status aprovado, evidenciada na Imagem 03, confirmando a disponibilidade integral dos arquivos necessários para o início da ingestão na camada Bronze.

IMAGEM 03 — Execução do notebook de validação da landing zone



The screenshot shows a Jupyter Notebook window titled 'idacao_landing_zone'. The interface includes a search bar at the top right, tabs for 'Run', 'Help', 'Python', and 'Full', and a status bar indicating 'Last edit was now'. The code cell is executed, showing a success icon and 'Just now (25s)'. The code defines a dictionary 'arquivos_encontrados' by stripping the directory path from file names found in 'VOLUME_PATH'. It then calculates 'faltantes' (missing files) and 'extras' (extra files) by comparing 'arquivos_encontrados' with 'arquivos_esperados'. The code prints the directory path, the number of expected and found files, the list of missing files, and the list of extra files. An assertion is used to check if there are any missing files, with a message in Portuguese. Finally, it prints the status 'APROVADO' and a confirmation message. The output shows the directory path as '/Volumes/main_catalog/bronze/olist_raw', 9 expected files, 9 found files, and empty lists for missing and extra files. A red arrow points to the empty list for missing files. The status is 'APROVADO' and the confirmation message is 'Todos os arquivos obrigatórios estão disponíveis na landing zone.'

```
arquivos_encontrados = {
    arquivo.name.rstrip("/")
    for arquivo in dbutils.fs.ls(VOLUME_PATH)
}

faltantes = arquivos_esperados - arquivos_encontrados
extras = arquivos_encontrados - arquivos_esperados

print(f"Diretório validado: {VOLUME_PATH}")
print(f"Arquivos obrigatórios esperados: {len(arquivos_esperados)}")
print(f"Arquivos encontrados no Volume: {len(arquivos_encontrados)}")
print(f"Arquivos obrigatórios faltantes: {sorted(faltantes)}")
print(f"Arquivos adicionais: {sorted(extras)}")

assert not faltantes, (
    "Validação reprovada. Arquivos obrigatórios ausentes: "
    + ", ".join(sorted(faltantes))
)

print("\nSTATUS: APROVADO")
print("Todos os arquivos obrigatórios estão disponíveis na landing zone.")
```

> [See performance \(1\)](#)

Diretório validado: /Volumes/main_catalog/bronze/olist_raw
Arquivos obrigatórios esperados: 9
Arquivos encontrados no Volume: 9
Arquivos obrigatórios faltantes: []
Arquivos adicionais: []

STATUS: APROVADO
Todos os arquivos obrigatórios estão disponíveis na landing zone.

Fonte: A autora (2026).

2.3 CAMADA BRONZE

Após a validação da landing zone, foi desenvolvido o notebook 02_ingestao_bronze, responsável por ingerir os arquivos CSV brutos disponibilizados no Unity Catalog Volume main_catalog.bronze.olist_raw e persistir seus conteúdos como tabelas Delta gerenciadas no schema main_catalog.bronze.

A rotina foi implementada por meio de um mapeamento explícito entre cada arquivo de origem e sua respectiva tabela de destino. Foram criadas as tabelas bronze_orders, bronze_order_items, bronze_order_payments,

bronze_order_reviews, bronze_customers, bronze_products, bronze_sellers, bronze_geolocation e bronze_category_translation. Dessa forma, cada entidade operacional do dataset foi mantida separadamente, preservando os relacionamentos que serão utilizados nas etapas posteriores de transformação e modelagem.

Durante a ingestão, os arquivos foram lidos no formato CSV com cabeçalho e sem inferência automática de schema. As colunas de origem foram inicialmente preservadas como texto, sem aplicação de regras de negócio, conversões de tipo, deduplicação, preenchimento de valores ausentes ou exclusão de registros.

Essa decisão é coerente com a finalidade da camada Bronze: registrar os dados recebidos no formato mais próximo possível da fonte, permitindo que tratamentos posteriores sejam reproduzíveis, auditáveis e separados da captura inicial.

Além dos atributos originais, foram adicionados quatro metadados técnicos a cada tabela: `source_file`, que identifica o arquivo CSV de origem; `ingestion_timestamp_utc`, que registra o momento da ingestão; `pipeline_run_id`, que identifica a execução específica do notebook; e `record_hash`, calculado com o algoritmo SHA-256 sobre as colunas originais do registro. Esses atributos ampliam a rastreabilidade e permitem auditoria da carga, investigação de falhas e apoio à identificação de registros duplicados em evoluções futuras do pipeline.

Após a persistência dos dados, o notebook executou uma validação pós-carga. A rotina comparou a lista de nove tabelas obrigatórias prevista no projeto com os objetos efetivamente existentes no schema Bronze. A execução foi aprovada somente quando nenhuma tabela obrigatória estava ausente, confirmando a conclusão da ingestão e a disponibilidade das entidades necessárias para a camada Silver.

IMAGEM 04 — Validação pós-carga do notebook 02_ingestao_bronze

The screenshot shows a Databricks notebook with the following sections:

- 4: Função de ingestão**: A Python cell that defines a function to ingest data from a source into a target table.
- 5: Executar a ingestão**: A Python cell that iterates over a list of tables and calls the ingestion function.
- 6: Validar tabela criada**: A Python cell that checks if the expected tables were created.

The output of the notebook shows the following tables created:

- Tabela criada: main_catalog.bronze.bronze_customers | Linhas: 99441
- Tabela criada: main_catalog.bronze.bronze_geolocation | Linhas: 1000163
- Tabela criada: main_catalog.bronze.bronze_order_items | Linhas: 112658
- Tabela criada: main_catalog.bronze.bronze_order_payments | Linhas: 103886
- Tabela criada: main_catalog.bronze.bronze_order_reviews | Linhas: 104162
- Tabela criada: main_catalog.bronze.bronze_orders | Linhas: 99441
- Tabela criada: main_catalog.bronze.bronze_products | Linhas: 32951
- Tabela criada: main_catalog.bronze.bronze_sellers | Linhas: 3095
- Tabela criada: main_catalog.bronze.bronze_category_translation | Linhas: 71

The output of the validation step shows:


- Tabelas esperadas: 9
- Tabelas encontradas: 9
- Tabelas faltantes: []
- STATUS: APROVADO - todas as tabelas Bronze foram criadas.

A red arrow points to the "STATUS: APROVADO" message.

Fonte: A autora (2026).

As tabelas foram persistidas como tabelas Delta gerenciadas pelo Unity Catalog, conforme Imagem 05. Nessa modalidade, o Unity Catalog mantém os metadados e administra o armazenamento subjacente das tabelas, apoiando governança centralizada e preparando os dados para as transformações posteriores do Lakehouse.

IMAGEM 05 — Tabelas Delta persistidas no schema bronze



Fonte: A autora (2026).

A camada Bronze resultante constitui a base rastreável do pipeline. A próxima etapa utilizará essas tabelas para padronização de tipos, limpeza, tratamento de dados ausentes, validações de qualidade, cálculo de indicadores logísticos e criação das estruturas Silver e Gold voltadas à análise de confiabilidade logística e satisfação do cliente.

2.4 CAMADA SILVER

Após a ingestão dos arquivos brutos na camada Bronze, foi implementado o notebook 03_transformacao_silver, responsável por transformar as tabelas do schema main_catalog.bronze em estruturas tratadas e confiáveis no schema main_catalog.silver.

A camada Silver representa a etapa de refinamento do Lakehouse: nela, os dados recebidos são tipados, padronizados, validados, deduplicados e enriquecidos antes de serem utilizados pela camada analítica Gold.

O notebook foi desenvolvido para ser reexecutável. Em cada execução, as tabelas Silver são recriadas com a opção de sobrescrita controlada de schema, garantindo que a mesma entrada Bronze gere a mesma estrutura de saída, sem acúmulo de colunas derivadas ou duplicação de registros. Essa característica é essencial para a reprodutibilidade do pipeline e para uma futura automação da carga.

A transformação iniciou pelas entidades de referência: clientes, sellers, produtos e tradução de categorias. Identificadores técnicos, como `customer_id`, `customer_unique_id`, `seller_id` e `product_id`, foram padronizados por remoção de espaços adicionais.

Além disso, atributos de texto foram normalizados com remoção de espaços duplicados, conversão para letras minúsculas quando apropriado e padronização de cidades. Estados foram convertidos para letras maiúsculas, e prefixos de CEP foram tratados como texto com cinco posições, preservando zeros à esquerda.

Em produtos, campos numéricos foram convertidos para os tipos adequados e nomes inconsistentes da fonte foram corrigidos no modelo. Os dados de pedidos foram convertidos para tipos temporais explícitos, abrangendo os eventos de compra, aprovação, envio à transportadora, entrega ao cliente e data estimada de entrega.

Os registros com chaves obrigatórias ausentes, data de compra inválida ou status fora do domínio esperado são segregados na tabela `silver_quarantine_orders`. Para itens de pedido, foram validadas a presença de `order_id`, `order_item_id`, `product_id` e `seller_id`, além da validade de valores monetários de preço e frete. Registros que não atenderam a essas regras são armazenados em `silver_quarantine_order_items`.

A utilização de tabelas de quarentena permite preservar registros problemáticos para auditoria em vez de removê-los silenciosamente. Esse padrão evita que dados inválidos sejam propagados para as tabelas confiáveis da Silver e da Gold posteriormente, ao mesmo tempo que mantém evidência sobre problemas de origem. A validação, limpeza e isolamento de dados inválidos na etapa de transformação são práticas compatíveis com os mecanismos de qualidade de dados suportados no Databricks.

Também foram aplicadas regras de deduplicação conforme a granularidade de cada entidade. Clientes foram deduplicados por `customer_id`; sellers por `seller_id`; produtos por `product_id`; pedidos por `order_id`; itens por `order_id` e `order_item_id`;

traduções por `product_category_name`; e avaliações por `review_id`. Essas chaves foram escolhidas de acordo com o papel de cada tabela e reduzem o risco de duplicação de métricas em relacionamentos posteriores.

Para evitar distorções causadas por relacionamentos de um-para-muitos (1-N), pagamentos foram agregados antes de qualquer integração analítica, gerando a tabela `silver_payments_order_agg` com total pago, número de registros de pagamento, maior quantidade de parcelas e modalidades utilizadas por pedido. Avaliações também foram agregadas por pedido na tabela `silver_reviews_order_agg`, contendo nota média, menor e maior nota, quantidade de avaliações e data da avaliação mais recente.

Durante essa transformação, foram identificados valores temporais incompatíveis com o formato esperado no atributo `review_answer_timestamp`. A conversão foi implementada com `try_to_timestamp`, que transforma datas inválidas em valores nulos sem interromper o pipeline. Essa abordagem mantém o registro disponível para auditoria e permite que a inconsistência seja mensurada posteriormente na análise de qualidade. A função tolerante retorna NULL quando não consegue interpretar a entrada como timestamp, inclusive com SQL habilitado.

A geolocalização foi consolidada por prefixo de CEP na tabela `silver_geolocation_zip_agg`. Foram validadas coordenadas dentro de limites geográficos plausíveis para o Brasil antes da agregação. Como a fonte possui múltiplas coordenadas para um mesmo prefixo de CEP, latitude e longitude foram agregadas por CEP, evitando duplicação de linhas quando os dados de localização forem associados a clientes ou sellers.


A tabela operacional `silver_order_service_base` foi criada no grão de um pedido, integrando pedidos, dados de clientes, itens agregados, pagamentos agregados e avaliações agregadas. Nessa estrutura foram derivados os atributos comerciais `product_total_value`, `freight_total_value`, `gmv_total_value`, `order_item_count`, `distinct_product_count`, `distinct_seller_count` e `avg_freight_to_price_ratio`. Também foram calculadas as métricas logísticas `actual_delivery_days`, `delivery_delay_days`, `delivery_early_days`, `is_delivered`, `is_delivery_late` e `is_delivery_on_time`.

A tabela `silver_order_service` representa a versão enriquecida da tabela-base. Ela inclui o seller principal de referência, quantidade de sellers por pedido, atributos

de localização de seller e cliente, distância aproximada entre origem e destino, faixas de distância, classificação de desempenho de entrega e faixa de avaliação. A distância geográfica foi calculada a partir de coordenadas agregadas por prefixo de CEP.

Por se tratar de uma estimativa baseada em CEP e por um pedido poder conter mais de um seller, a medida deve ser interpretada como distância aproximada. Para análises que envolvam distância, serão priorizados pedidos com seller_count = 1, nos quais a origem do seller é inequívoca.

IMAGEM 06 — Execução completa e aprovada do notebook 03_transformacao_silver



```
03_transformacao_silver x +
Python Full Last edit was 5 minutes ago

13: Criar tabela operacional de serviço por pedido
with silver_writer(writer_options, "silver_order_service_base", )
> See performance (2)
> 7 dataframes: customers, items, order_items_agg, order_service, orders, payments,...
Tabela Silver criada: main_catalog.silver.silver_order_service_base | Linhas: 99441

14: Distância aproximada por pedido
order_service_base = spark.table(f"{SILVER}.silver_order_service_base") order_it ...
> See performance (2)
Tabela Silver criada: main_catalog.silver.silver_order_service | Linhas: 99441


15: Validação da silver
tabelas_silver_esperadas = { "silver_customers", "silver_sellers", " ...
> See performance (1)
Tabelas Silver esperadas: 13
Tabelas Silver encontradas: 13
Tabelas Silver faltantes: []
STATUS: APROVADO – todas as tabelas Silver foram criadas.
```

Fonte: A autora (2026).

Ao final da execução, demonstrada na Imagem 06 anterior, foram disponibilizadas treze tabelas no schema main_catalog.silver: silver_customers, silver_sellers, silver_category_translation, silver_products, silver_orders, silver_quarantine_orders, silver_order_items, silver_quarantine_order_items, silver_payments_order_agg, silver_reviews_order_agg, silver_geolocation_zip_agg,

silver_order_service_base e silver_order_service. A validação final compara programaticamente essa relação de objetos esperados com as tabelas efetivamente persistidas e somente aprova o notebook quando nenhuma tabela está ausente. As tabelas estão evidenciadas a seguir.

IMAGEM 07 — Tabelas Silver tratadas, validadas e enriquecidas disponíveis



The screenshot shows the Databricks Catalog Explorer interface. On the left, a sidebar lists the catalog structure: 'My organization' > 'workspace' > 'system' > 'main_catalog' > 'silver'. The 'silver' schema is selected, showing a list of 13 tables. On the right, the 'Overview' tab for the 'silver' schema is displayed, showing a description and a table listing 13 tables with their owners.

Name	Owner
silver_category_translation	barbjsp
silver_customers	barbjsp
silver_geolocation_zip_agg	barbjsp
silver_order_items	barbjsp
silver_order_service	barbjsp
silver_order_service_base	barbjsp
silver_orders	barbjsp
silver_payments_order_agg	barbjsp
silver_products	barbjsp
silver_quarantine_order_items	barbjsp
silver_quarantine_orders	barbjsp
silver_reviews_order_agg	barbjsp
silver_sellers	barbjsp

Fonte: A autora (2026).

As tabelas Silver constituem a base confiável para a etapa seguinte de modelagem dimensional. A camada Gold utilizará essas estruturas para criar

dimensões, tabelas fato e marts analíticos voltados à análise de confiabilidade logística, satisfação do cliente e desempenho comercial.

2.5 CAMADA GOLD

Após a limpeza, padronização, validação e enriquecimento dos dados na camada Silver, foi implementado o notebook 04_modelagem_gold, responsável pela criação da camada Gold no schema main_catalog.gold. Essa camada constitui a zona de consumo analítico do Lakehouse e foi organizada em um modelo dimensional no formato de esquema estrela, orientado às perguntas de negócio sobre vendas, confiabilidade logística, desempenho de sellers e satisfação do cliente.

A camada Gold foi construída exclusivamente a partir das tabelas Silver. Essa decisão preserva a arquitetura Medallion adotada no MVP: a Bronze mantém a captura rastreável dos dados de origem; a Silver consolida tipagem, limpeza, validação e enriquecimento; e a Gold disponibiliza estruturas dimensionais e agregações prontas para consulta, indicadores e análises.

Em modelagem dimensional, tabelas fato registram eventos e medidas, enquanto dimensões fornecem o contexto descritivo necessário para filtrar, agrupar e interpretar esses eventos.

A implementação foi desenvolvida de forma reexecutável. Todas as tabelas Gold são persistidas como tabelas Delta gerenciadas pelo Unity Catalog e recriadas por sobrescrita controlada de schema. Dessa forma, uma nova execução do notebook atualiza as estruturas analíticas a partir da Silver, sem necessidade de criação manual de tabelas e sem dependência da camada Bronze.

Foram criadas seis dimensões: dim_date, dim_customer, dim_product, dim_seller, dim_location e dim_service_band. A tabela dim_date contém atributos de calendário, como ano, mês, trimestre, dia da semana e indicador de fim de semana, associados às datas do ciclo do pedido. A tabela dim_customer consolida informações históricas por cliente anonimizado, incluindo quantidade de pedidos, GMV acumulado, ticket médio histórico, primeira e última compra, recorrência e faixa de valor.

A tabela dim_product reúne categoria e atributos físicos de cada produto. A tabela dim_seller centraliza localização padronizada e indicadores históricos de receita e pedidos por seller. A tabela dim_location organiza informações de localidade

aproximada de clientes e sellers por prefixo de CEP. Por fim, `dim_service_band` padroniza as classificações de distância, desempenho de entrega e avaliação utilizadas como segmentações analíticas.

A modelagem também incluiu duas tabelas fato com granularidades distintas. A tabela `fact_order_service` possui uma linha por pedido, identificada por `order_id`. Ela consolida medidas de valor de produtos, frete, GMV, pagamento, quantidade de itens, quantidade de sellers, nota de avaliação, prazo de entrega, atraso, antecedência, flags de SLA e distância aproximada entre seller e cliente. Essa fato é utilizada nas análises de confiabilidade logística e experiência pós-venda.


E a tabela `fact_order_item_sales`, por sua vez, possui uma linha por item de pedido, identificada pela combinação de `order_id` e `order_item_id`. Ela contém medidas de preço, frete, GMV do item e índice frete/preço, além das referências ao produto e seller.

A separação entre fatos no grão de pedido e no grão de item evita duplicação indevida: um pedido pode conter múltiplos itens, mas indicadores como entrega, avaliação e pagamento pertencem ao pedido e não devem ser repetidos artificialmente em cálculos operacionais.

Além das dimensões e fatos, foram criados quatro marts analíticos. O mart `mart_logistics_performance` consolida indicadores operacionais por seller, incluindo pedidos entregues, GMV, prazo médio, taxa de atraso, dias médios de atraso, frete médio, nota média e taxa de avaliações baixas. O mart `mart_service_risk` classifica sellers em risco baixo, médio ou alto, considerando conjuntamente a taxa de atraso, satisfação e relevância comercial medida por GMV.

O mart `mart_customer_experience` compara distância, atraso, prazo, frete e avaliação para investigar padrões associados à experiência do cliente. Por fim, `mart_monthly_operations` organiza indicadores mensais de pedidos, GMV, ticket médio, prazo, atraso e satisfação, permitindo avaliar sazonalidade e pressão operacional ao longo do período histórico.

IMAGEM 08 — Tabelas Gold dimensionais, fatos e marts analíticos persistidos



Fonte: A autora (2026).

Ao final do notebook 04_modelagem_gold, foi executada uma validação automatizada. A rotina comparou a relação esperada de doze tabelas Gold com os objetos efetivamente persistidos no Unity Catalog. A execução foi aprovada somente após confirmar que nenhuma dimensão, tabela fato ou mart analítico obrigatório estava ausente, conforme demonstrado na Imagem 09. Esse mecanismo reforça a reprodutibilidade da modelagem e impede que análises posteriores sejam executadas sobre uma camada Gold incompleta.

IMAGEM 09 — Validação automatizada do notebook 04_modelagem_gold

```
accao_landing_zone 02_ingestao_bronze 03_transformacao_silver 04_modelagem_gold x 07_governanca
Run Help Python Full Last edit was 13 minutes ago

▶ 3 minutes ago (4s) 15: Criar mart_monthly_oper...
    "mart_monthly_operations",
  )
> See performance (2)
> mart_monthly_operations: pyspark.sql.connect.dataframe.DataFrame = [purchase_year_month: string, order_count: long ... 5 mo
Tabela Gold criada: main_catalog.gold.mart_monthly_operations | Linhas: 25

▶ 3 minutes ago (2s) 16: Validação gold
    tabelas_gold_esperadas = {      "dim_date",      "dim_customer",      "dim_product" ...
> See performance (1)
Tabelas Gold esperadas: 12
Tabelas Gold encontradas: 12
Tabelas Gold faltantes: []
STATUS: APROVADO - todas as tabelas Gold foram criadas.
```

Fonte: A autora (2026).

A camada Gold resultante é a base para as etapas de análise de qualidade e análise de negócio. Por meio dessas tabelas, será possível responder às perguntas delineadas no objetivo do MVP, como identificar sellers, categorias e regiões com maior risco logístico; comparar satisfação entre pedidos no prazo e pedidos atrasados; avaliar a associação entre distância aproximada, frete e prazo de entrega; e analisar a evolução mensal dos indicadores operacionais.

2.6 GOVERNANÇA, SEGURANÇA E RASTREABILIDADE

A construção de uma pipeline de dados não se encerra na ingestão, limpeza e modelagem das tabelas. Para que os dados possam ser reutilizados com confiança, mantidos ao longo do tempo e auditados, é necessário estabelecer mecanismos de governança. Neste MVP, a governança foi implementada no Unity Catalog do Databricks, utilizando o catálogo main_catalog como camada central de organização e gestão dos ativos de dados.

A estrutura do Lakehouse foi segmentada nos schemas bronze, silver e gold. Essa separação não possui apenas finalidade organizacional: ela delimita responsabilidades e reduz o risco de consumo inadequado dos dados.

A camada Bronze mantém os registros recebidos em formato próximo ao original; a Silver concentra limpeza, tipagem, validações, deduplicação, quarentena e enriquecimento operacional; e a Gold disponibiliza dimensões, tabelas fato e marts preparados para consumo analítico. A separação por camadas permite identificar a maturidade e o nível de confiabilidade de cada ativo, além de apoiar a manutenção do pipeline.

Foi criado o notebook `07_governanca_catalogo`, responsável por concentrar de forma reexecutável as definições de documentação e classificação dos ativos. O notebook atua como uma fonte versionável de metadados técnicos e de negócio: em vez de depender de descrições inseridas manualmente e sem rastreabilidade, comentários e tags são aplicados por código após a execução das camadas Bronze, Silver e Gold. Essa decisão permite restaurar a documentação caso uma tabela seja recriada durante uma nova execução do pipeline.

Cada uma das 34 tabelas produzidas pelo MVP recebeu uma descrição correspondente de contexto no Unity Catalog, conforme mostrado na Imagem 10. A descrição de cada tabela informa seu objetivo, camada arquitetural, granularidade, principais transformações aplicadas, finalidade de consumo e latência-alvo.

As granularidades foram documentadas para evitar interpretações incorretas e duplicação de métricas. Por exemplo, `fact_order_service` possui uma linha por pedido, enquanto `fact_order_item_sales` possui uma linha por item de pedido; a separação entre esses grãos evita que indicadores de entrega, pagamento e avaliação sejam replicados ao analisar itens.

IMAGEM 10 — Execução do notebook `07_governanca_catalogo`

acao_landing_zone 02_ingestao_bronze 03_transformacao_silver 04_modelagem_gold 07_governanca_catalogo

Python Full Last edit was 7 minutes ago

7. Aplicar descrições e tags em tabelas

> [See performance \(50\)](#)

> `table_documentation_df: pyspark.sql.connect.dataframe.DataFrame = [schema_name: string, table_name: string ... 2 more fields]`

Table +

	A ^B C schema_name	A ^B C table_name	A ^B C status	A ^B C error_message
1	bronze	bronze_category_translation	APPLIED	null
2	bronze	bronze_customers	APPLIED	null
3	bronze	bronze_geolocation	APPLIED	null
4	bronze	bronze_order_items	APPLIED	null
5	bronze	bronze_order_payments	APPLIED	null
6	bronze	bronze_order_reviews	APPLIED	null
7	bronze	bronze_orders	APPLIED	null
8	bronze	bronze_products	APPLIED	null
9	bronze	bronze_sellers	APPLIED	null
10	gold	dim_customer	APPLIED	null
11	gold	dim_date	APPLIED	null
12	gold	dim_location	APPLIED	null
13	gold	dim_product	APPLIED	null
14	gold	dim_seller	APPLIED	null
15	gold	dim_service_band	APPLIED	null
16	gold	fact_order_item_sales	APPLIED	null
17	gold	fact_order_service	APPLIED	null
18	gold	mart_customer_experience	APPLIED	null
19	gold	mart_logistics_performance	APPLIED	null
20	gold	mart_monthly_operations	APPLIED	null

34 rows 44.832s runtime

STATUS: APROVADO – comentários e tags aplicados a todas as tabelas Bronze, Silver e Gold.

Fonte: A autora (2026).

As tabelas receberam também tags padronizadas para facilitar a descoberta, classificação e gestão dos dados. Foram utilizadas tags como `data_layer`, `business_domain`, `data_grain`, `data_classification`, `quality_status`, `latency_target`, `project`, `data_source`, `usage_scope` e `refresh_pattern`.

Essas tags registram, respectivamente, a camada Medallion do objeto, o domínio de negócio, sua granularidade, o nível de classificação, o status de qualidade, a meta de disponibilidade, o projeto associado, a origem dos dados, o escopo acadêmico não comercial e o padrão de atualização batch manual do MVP.

A classificação de dados foi aplicada de acordo com o conteúdo de cada ativo. Identificadores técnicos anonimizados de clientes e sellers foram classificados como

anonymized ou confidential, pois não contêm identificação direta, mas requerem tratamento responsável da mesma forma.

Prefixos de CEP, cidades, estados e coordenadas geográficas foram classificados como localização aproximada ou informação restrita. Valores financeiros, como preço, frete, GMV e pagamento, foram classificados como métricas financeiras de uso interno. O projeto não contém nome, CPF, e-mail, telefone, endereço completo, dados de cartão ou qualquer outro identificador pessoal direto. Ainda assim, não devem ser realizadas tentativas de reidentificação de clientes ou sellers.

Também foram adicionados comentários para todas as colunas das tabelas Bronze, Silver e Gold. Os comentários descrevem o significado de cada campo, seu uso analítico ou operacional, regras de derivação, limitações conhecidas e domínio esperado quando aplicável.

Campos categóricos, como por exemplo `order_status`, `payment_types`, `distance_band`, `delivery_performance_band`, `review_band`, `customer_value_band` e `service_risk_level`, possuem seus valores permitidos documentados. Já os campos booleanos, como `is_delivered`, `is_delivery_late`, `is_delivery_on_time`, `is_low_review` e `is_repeat_customer`, possuem a semântica de `true`, `false` e `null` explicitamente registrada.

A documentação de campos numéricos também estabelece domínios esperados. Valores monetários de preço, frete, GMV e pagamento devem ser maiores ou iguais a zero; notas de avaliação pertencem à escala de 1 a 5; percentuais de atraso e avaliações baixas devem variar entre 0 e 100; e as métricas de distância e prazo representam valores aproximados calculados pelo pipeline.

O campo `seller_customer_distance_km`, por exemplo, foi documentado como uma estimativa geográfica baseada em coordenadas agregadas por prefixo de CEP e pela fórmula de Haversine, não devendo ser interpretado como rota real de transporte ou distância exata entre endereços.

A governança inclui, ainda, metadados técnicos de rastreabilidade nas camadas Bronze, Silver e Gold. Na Bronze, cada registro possui `source_file`, `ingestion_timestamp_utc`, `pipeline_run_id` e `record_hash`. Esses atributos permitem identificar o arquivo de origem, o momento da ingestão, a execução que gerou o registro e uma assinatura SHA-256 do conteúdo recebido.

Na Silver e na Gold, os campos `silver_pipeline_run_id`, `silver_processed_timestamp_utc`, `gold_pipeline_run_id` e `gold_processed_timestamp_utc` registram os processamentos realizados em cada camada. Esses metadados apoiam auditoria, investigação de incidentes, reproprocessamento e análise de linhagem técnica.

O catálogo de dados também registra metas de latência. Como a fonte utilizada é histórica e a coleta foi manual, os valores definidos não representam uma operação de produção observada, mas sim metas arquiteturais para evolução do pipeline.

A camada Bronze possui meta de disponibilidade D+0 após o recebimento do arquivo; a Silver possui meta D+0 a D+1 após a conclusão da Bronze; e a Gold possui meta D+1 após a conclusão da Silver. Como referência de serviço de ponta a ponta, foi estabelecida a meta de disponibilização analítica em até D+1 após a chegada de novos dados.

A cobertura de documentação foi validada de forma programática por meio do `INFORMATION_SCHEMA.COLUMNS` do Unity Catalog. A rotina contabiliza o total de colunas por tabela, identifica quantas possuem comentário preenchido e interrompe a execução caso existam colunas sem documentação. A aprovação da validação, com cobertura de 100%, comprova que os metadados foram efetivamente persistidos no catálogo e não apenas descritos no relatório, conforme mostrado a seguir na Imagem 11.

IMAGEM 11 — Resultado da validação de cobertura do catálogo de dados

ao_landing_zone 02_ingestao_bronze 03_transformacao_silver 04_modelagem_gold 07_governanca_catalogo x +

Help Python Full Last edit was 9 minutes ago

16: Validação de cobertura de comentários

```
comment_coverage_df = spark.sql( f""" SELECT table_schema AS sch ...
```

> See performance (2)

Table +

	schema_name	table_name	total_columns	documented_columns	documentation_coverage_pct
1	bronze	bronze_category_translation	6	6	100.00
2	bronze	bronze_customers	9	9	100.00
3	bronze	bronze_geolocation	9	9	100.00
4	bronze	bronze_order_items	11	11	100.00
5	bronze	bronze_order_payments	9	9	100.00
6	bronze	bronze_order_reviews	11	11	100.00
7	bronze	bronze_orders	12	12	100.00
8	bronze	bronze_products	13	13	100.00
9	bronze	bronze_sellers	8	8	100.00
10	gold	dim_customer	13	13	100.00
11	gold	dim_date	13	13	100.00
12	gold	dim_location	8	8	100.00
13	gold	dim_product	12	12	100.00
14	gold	dim_seller	9	9	100.00
15	gold	dim_service_band	6	6	100.00

34 rows 3.165s runtime

Colunas sem comentário: 0
 STATUS: APROVADO – 100% das colunas Bronze, Silver e Gold possuem comentários no Unity Catalog.



Fonte: A autora (2026).

No contexto de segurança, o MVP foi implementado em um workspace acadêmico individual. Portanto, não foram criados usuários, grupos ou concessões fictícias de acesso. Essa decisão evita simular controles que não existem e mantém aderência ao princípio de menor privilégio. A proprietária do catálogo mantém os privilégios necessários para criar, alterar, consultar e documentar os ativos do projeto. A auditoria de permissões foi realizada por comandos SHOW GRANTS no catálogo e nos schemas bronze, silver e gold.

Em uma implementação corporativa, a política de acesso recomendada seria separar os perfis de engenharia de dados, analytics e negócio. Para acessar objetos no Unity Catalog, uma identidade precisa de USE CATALOG no catálogo, USE SCHEMA no schema correspondente e do privilégio específico à ação, como SELECT para leitura ou MODIFY para escrita.


A governança de permissões deve seguir o princípio de menor privilégio: cada pessoa ou serviço deve possuir apenas os acessos necessários para desempenhar

sua função. Assim, analistas de negócio devem consumir prioritariamente tabelas Gold, sem permissão de alteração; engenheiras de dados devem manter permissão de escrita nas camadas de processamento; e objetos de quarentena devem permanecer restritos aos responsáveis pela qualidade e operação da pipeline.

A rastreabilidade também é fortalecida pela linhagem de dados. O pipeline foi implementado com tabelas Delta gerenciadas pelo Unity Catalog, e cada transformação foi executada por notebooks Databricks.

Dessa forma, a aba Lineage do Catalog Explorer pode apresentar as dependências entre as tabelas Bronze, Silver e Gold, permitindo analisar a origem de uma métrica ou avaliar o impacto de uma alteração na fonte. Em ambientes Unity Catalog, a linhagem de operações executadas em compute habilitado é capturada automaticamente para dependências entre tabelas e colunas.

IMAGEM 12 — Exemplo de linhagem de dados no Unity Catalog



Fonte: A autora (2026).

Em síntese, a governança implementada estabelece uma base de manutenção e auditoria para o MVP. A combinação de separação por camadas, catálogo de dados, comentários, tags, classificação, metadados de execução, validação automatizada de cobertura, auditoria de permissões e linhagem reduz a dependência de conhecimento tácito.

Assim, outro profissional consegue entender quais dados existem, qual é seu significado, de onde vieram, como foram transformados, quais limitações possuem e quais ativos devem ser utilizados para análises de logística, vendas e satisfação do cliente.

2.7 QUALIDADE DOS DADOS

Após a construção das camadas Bronze, Silver e Gold, e documentação de todas as tabelas, foi implementado o notebook 05_analise_qualidade, responsável por avaliar a confiabilidade dos dados que sustentam o MVP. A qualidade de dados é indispensável para que indicadores de vendas, GMV, frete, prazo de entrega, atraso, satisfação do cliente e risco operacional sejam calculados e interpretados de forma confiável.

Uma pipeline pode ser tecnicamente executada sem erros e, ainda assim, gerar análises incorretas se os dados possuírem campos críticos ausentes, registros duplicados, valores fora do domínio permitido, relacionamentos inconsistentes ou ausência de rastreabilidade. Por essa razão, a análise de qualidade foi desenvolvida como uma etapa independente e somente de leitura, sem alterar, excluir ou recriar tabelas das camadas Bronze, Silver ou Gold.

O notebook 05_analise_qualidade analisa a qualidade em dois níveis. O primeiro nível realiza um perfil estrutural de todas as tabelas do Lakehouse: 9 tabelas Bronze, 13 tabelas Silver e 12 tabelas Gold, totalizando 34 tabelas. Nesse perfil são avaliados volume de registros, quantidade de colunas, presença de valores nulos ou vazios e cobertura de metadados de rastreabilidade.

O segundo nível aprofunda controles de negócio nas tabelas mais relevantes para o problema do MVP, principalmente pedidos, itens de pedido, fatos de serviço, fatos de vendas e dimensões de cliente, produto e seller.

A estratégia adotada combina cobertura ampla e profundidade analítica. Nem todo atributo nulo representa necessariamente um erro. Por exemplo, uma data de entrega pode estar ausente em pedidos cancelados ou não entregues; uma avaliação pode ser nula quando o cliente não avaliou a compra; e a distância entre seller e cliente pode não ser calculada quando não existem coordenadas geográficas suficientes para um dos prefixos de CEP.

Em contrapartida, atributos como identificador do pedido, identificador persistente do cliente e referência temporal da compra são essenciais para a integridade do modelo analítico e foram tratados como campos críticos.

As dimensões de qualidade avaliadas são apresentadas na tabela a seguir.

TABELA 05 - Dimensões de qualidade de dados

Dimensão de qualidade	Pergunta de controle	Verificações e métricas aplicadas
Compleitude	Os atributos essenciais estão preenchidos?	Contagem e percentual de valores nulos ou vazios por tabela e por campo crítico
Validade	Os valores pertencem ao formato e domínio esperados?	Status permitido, nota entre 1 e 5, GMV e frete não negativos, prazo e distância não negativos
Consistência	A relação entre campos segue regras lógicas?	Coerência entre flags de atraso e de entrega no prazo
Unicidade	Existem duplicações nas chaves de negócio?	Comparação entre número total de linhas e número de chaves distintas
Integridade referencial	Registros de fatos possuem dimensões correspondentes?	Contagem de registros órfãos entre fatos e dimensões
Plausibilidade	Valores são aceitáveis no contexto operacional?	Validação de faixas de prazo, frete, GMV, distância e avaliações
Outliers	Existem valores extremos que podem distorcer análises?	Percentis 1, 25, 50, 75 e 99 de GMV, frete, prazo, atraso e distância
Rastreabilidade	É possível identificar origem e processamento?	Presença e preenchimento de metadados técnicos em todas as tabelas
Atualidade	É possível identificar a última execução/processamento?	Timestamps de ingestão e processamento nas camadas Bronze, Silver e Gold

Fonte: A autora (2026).

O perfil foi aplicado às 34 tabelas do Lakehouse. Para cada tabela, foram calculados o número de linhas, o número de colunas, a quantidade de colunas com valores nulos ou vazios, o total de células nulas ou vazias e o percentual global de ausência de dados. Essa avaliação permite identificar estruturas com maior incidência de nulos e distinguir campos obrigatórios de atributos opcionais conforme o contexto operacional.

A completude dos campos críticos foi avaliada na tabela `main_catalog.gold.fact_order_service`, que representa o grão de um pedido e concentra os principais indicadores comerciais, logísticos e de satisfação. Foram verificados os atributos `order_id`, `customer_unique_id`, `purchase_date_key`, `gmv_total_value`, `order_status`, `delivery_date_key`, `review_score_avg` e `seller_customer_distance_km`.

A validação demonstrou que não existem valores nulos ou vazios em `order_id`, `customer_unique_id` e `purchase_date_key`, que são os atributos essenciais para identificação do pedido, identificação anonimizada do cliente e vínculo com a dimensão temporal. Da mesma forma, não foram identificados valores ausentes em `gmv_total_value` e `order_status`, assegurando a disponibilidade das medidas comerciais e do estado operacional de cada pedido.

A validade e a consistência foram verificadas por meio de regras explícitas. Foram avaliados status de pedido fora do domínio permitido, valores negativos de GMV, valores negativos de frete, notas de avaliação fora da escala de 1 a 5, prazos de entrega negativos, distâncias negativas e incoerências entre as flags `is_delivery_late` e `is_delivery_on_time`.

Os resultados demonstraram que foram identificadas 0 ocorrências inválidas nas regras de domínio e consistência avaliadas. Não foram encontrados status de pedido fora do conjunto permitido (`created`, `approved`, `invoiced`, `processing`, `shipped`, `delivered`, `unavailable` e `canceled`), nem valores negativos para GMV, frete, prazo de entrega ou distância aproximada. Também não foram identificadas notas de avaliação fora do intervalo de 1 a 5, tampouco inconsistências entre os indicadores de entrega atrasada e entrega no prazo.

A unicidade foi avaliada nas chaves de negócio das principais estruturas Silver e Gold. Foram verificadas as chaves `order_id` em `silver_orders` e `fact_order_service`;

a combinação `order_id + order_item_id` em `silver_order_items` e `fact_order_item_sales`; `customer_unique_id` em `dim_customer`; `product_id` em `dim_product`; e `seller_id` em `dim_seller`.

O resultado indicou 0 registros duplicados nas chaves avaliadas. Esse resultado é particularmente relevante porque o dataset possui relações naturalmente um-para-muitos: um pedido pode conter múltiplos itens e múltiplos pagamentos. A deduplicação e as agregações prévias implementadas na Silver impediram que tais relacionamentos multiplicassem artificialmente registros e valores financeiros na Gold.

A integridade referencial foi verificada entre tabelas fato e dimensões. Foram analisadas as relações entre `fact_order_service` e `dim_customer`, entre `fact_order_service` e `dim_seller`, entre `fact_order_item_sales` e `dim_product`, e entre `fact_order_item_sales` e `dim_seller`. A métrica utilizada foi a contagem de registros órfãos, isto é, registros presentes em uma fato cuja chave correspondente não foi localizada na dimensão relacionada.

Não foram identificados registros órfãos nas relações avaliadas, totalizando 0 ocorrências de quebra de integridade referencial. Isso confirma que as dimensões necessárias para interpretar os eventos de pedidos e itens de venda estão disponíveis e que os relacionamentos essenciais do esquema estrela foram preservados.

A efetividade da limpeza e do tratamento de dados foi analisada pela comparação entre os registros recebidos na Bronze, os registros válidos persistidos na Silver e os registros isolados em tabelas de quarentena. Os registros que não atendiam às regras mínimas, como chave obrigatória ausente, status inválido, data de compra inválida, preço inválido ou frete inválido, foram direcionados para `silver_quarantine_orders` e `silver_quarantine_order_items`.

IMAGEM 13 — Comparação entre registros Bronze, registros Silver e quarentena

11: Quarentena e efetividade do tratamento

```

* 100
/ F.col("bronze_row_count"),
4,
),
),
)

display(quarantine_summary_df)

```

> [See performance \(7\)](#)

> `quarantine_summary_df: pyspark.sql.connect.dataframe.DataFrame = [entity: string, bronze_row_count: long ... 3 more fields]`

	entity	bronze_row_count	silver_valid_row_count	silver_quarantine_row_count	quarantine_rate_pct
1	orders	99441	99441	0	0
2	order_items	112650	112650	0	0

2 rows 3.299s runtime

Fonte: A autora (2026).

Essa estratégia evita a exclusão silenciosa de informações e assegura rastreabilidade para falhas de origem. Os registros em quarentena permanecem disponíveis para auditoria, mas não são propagados para as tabelas Silver confiáveis ou para a Gold. A taxa de quarentena observada foi de 0% para pedidos e para itens de pedido.

A análise de outliers foi aplicada às medidas `gmv_total_value`, `freight_total_value`, `actual_delivery_days`, `delivery_delay_days` e `seller_customer_distance_km`. Foram calculados os percentis 1, 25, 50, 75 e 99 para observar a distribuição e identificar valores extremos capazes de afetar médias e interpretações estatísticas.

Os resultados indicaram que o percentil 99 do GMV por pedido foi de R\$ 1.763,25 e o do frete total por pedido alcançou R\$ 240,03. Para o prazo real de entrega, o percentil 99 foi de 44,03 dias, enquanto os dias de atraso apresentaram percentil 99 de 18,91 dias. Por fim, a distância aproximada entre seller e cliente atingiu 2.483,36 km no percentil 99, evidenciando a existência de pedidos com valores, custos de frete, prazos e deslocamentos significativamente superiores ao comportamento típico da base.

Os outliers não foram removidos automaticamente. No contexto de marketplace, pedidos de maior valor, fretes elevados, distâncias extensas, prazos

longos e atrasos relevantes podem representar situações reais e importantes para o negócio. Por esse motivo, esses registros foram preservados e serão interpretados nas análises posteriores com apoio de medianas, percentis e segmentações, evitando que médias isoladas conduzam a conclusões inadequadas.


A rastreabilidade estrutural foi avaliada em todas as 34 tabelas. Na camada Bronze, foram verificadas as colunas `source_file`, `ingestion_timestamp_utc`, `pipeline_run_id` e `record_hash`. Na Silver, foram avaliadas `silver_pipeline_run_id` e `silver_processed_timestamp_utc`. Na Gold, foram verificadas `gold_pipeline_run_id` e `gold_processed_timestamp_utc`.

A validação de rastreabilidade apresentou resultado aprovado, com ausência de metadados obrigatórios e cobertura de processamento consistente nas tabelas avaliadas. O resumo final indicou 0 ocorrências de falhas de rastreabilidade estrutural. Isso demonstra que os registros possuem informações suficientes para identificar a origem dos dados, o momento de ingestão ou processamento e a execução do pipeline responsável pela criação de cada camada.

Como a base Olist é histórica e foi carregada manualmente, o MVP não mede um atraso real de atualização diária da fonte. Em vez disso, foram registrados timestamps de ingestão e processamento, permitindo identificar a última execução em tabelas representativas da Bronze, Silver e Gold. Para uma evolução produtiva, a arquitetura estabelece como meta disponibilidade D+0 entre as camadas e disponibilidade analítica em até D+1 após a chegada de novos arquivos.

Em ambientes de produção, o monitoramento de qualidade pode acompanhar continuamente sinais de completude e freshness, comparando volume, presença de dados e recência de atualizações ao comportamento histórico das tabelas.

IMAGEM 14 — Resumo final das validações de qualidade



	quality_dimension	scope	acceptance_criterion	issue_count	status
1	Completeness de chaves críticas	fact_order_service.order_id, customer_unique_id e order_purchase_timesta...	Sem nulos ou vazios	0	APROVADO
2	Integridade referencial	Fatos relacionados a dimensões	orphan_record_count = 0	0	APROVADO
3	Rastreabilidade estrutural	Metadados obrigatórios por camada	Sem metadados ausentes e cobertura de 100...	0	APROVADO
4	Unicidade	Chaves de pedidos, itens e dimensões	duplicate_rows = 0	0	APROVADO
5	Validade de domínio e medidas	Status, GMV, frete, review, prazo, distância e flags	Nenhuma ocorrência inválida	0	APROVADO

5 rows 4.060s runtime

STATUS: APROVADO - controles críticos de qualidade, integridade e rastreabilidade foram validados.

Fonte: A autora (2026).

O status final da etapa foi APROVADO, indicando que os controles críticos de qualidade, integridade e rastreabilidade definidos para o MVP foram atendidos. A camada Gold pode, portanto, ser utilizada como fonte confiável para a próxima etapa de análise de negócio, na qual serão respondidas as perguntas sobre vendas, confiabilidade logística, atrasos, frete, distância aproximada, desempenho de sellers e satisfação de clientes.


2.8 PIPELINE

Para tornar a execução da pipeline reproduzível e reduzir a dependência de operações manuais, os notebooks de ingestão, transformação, modelagem e qualidade foram organizados em um Job no Databricks. O Job `job_omnisales_lakehouse_pipeline` foi configurado com quatro tarefas sequenciais: `bronze_ingestion`, `silver_transformation`, `gold_modeling` e `data_quality_validation`.

A execução segue uma dependência controlada: a camada Silver é processada somente após a conclusão bem-sucedida da Bronze; a Gold somente após a Silver; e as validações de qualidade somente após a construção da Gold. Esse encadeamento evita que dados incompletos ou falhas de processamento sejam propagados para as camadas analíticas.

A execução do Job foi concluída com sucesso, com todas as quatro tarefas apresentando status `Succeeded`, conforme mostrado na Imagem 15 abaixo. O fluxo completo foi finalizado em 18 minutos e 29 segundos, e a execução registrou linhagem de 35 tabelas upstream e 34 tabelas downstream. Esses registros demonstram que a solução possui rastreabilidade ponta a ponta e pode ser reexecutada de forma padronizada.

IMAGEM 15 — Execução orquestrada do pipeline OmniSales no Databricks Jobs



Fonte: A autora (2026).

No contexto do MVP, a execução foi mantida sob demanda, pois a fonte é histórica e baseada em arquivos CSV. Em uma evolução produtiva, o mesmo Job poderia receber agendamento periódico ou ser disparado automaticamente após a chegada de novos arquivos, com configuração adicional de alertas, retentativas e monitoramento de SLA.

2.9 ANÁLISE DE DADOS

Após a aprovação dos controles de qualidade, foi desenvolvido o notebook 06_analise_dados. O notebook utiliza exclusivamente dados da camada Gold para

responder às cinco perguntas prioritárias do MVP, definidas na primeira etapa do desenvolvimento.

O objetivo desta etapa foi demonstrar que a arquitetura Lakehouse permite integrar a jornada de compra e pós-venda (pedido, item vendido, preço, frete, seller, localização, entrega e avaliação) em uma visão analítica única. Assim, a organização pode identificar não apenas onde estão o volume e o faturamento, mas também em quais categorias, sellers e regiões o desempenho comercial convive com risco logístico e menor satisfação do cliente.

As análises foram realizadas por meio de consultas SQL somente leitura e utilizaram as tabelas fato `fact_order_service` e `fact_order_item_sales`, as dimensões `dim_customer`, `dim_product` e `dim_seller`, e as marts `mart_logistic_performance`, `mart_customer_experience` e `mart_service_risk`.

Foram preservados os diferentes grãos analíticos do modelo: pedido na fato de serviço, item na fato de vendas e indicadores consolidados nas marts. Essa separação evita dupla contagem de métricas financeiras e logísticas.

2.9.1 Pergunta 1 — Concentração comercial

A primeira análise identificou a concentração de pedidos, receita de produtos, frete, GMV e ticket médio por categoria, seller e estado do cliente. A análise é apresentada em três recortes: categoria de produto, seller e estado do cliente. Para evitar duplicidade de valores, o recorte por categoria e seller utiliza a fato no grão de item; já o recorte por estado do cliente utiliza a fato no grão de pedido.

A query utilizada em SQL para o recorte de CATEGORIA foi:

```
%sql  
...
```

```
SELECT  
  COALESCE(p.product_category_name, 'not_available') AS analysis_group,  
  'category' AS analysis_level,  
  COUNT(DISTINCT i.order_id) AS order_count,  
  COUNT(*) AS item_count,  
  ROUND(SUM(i.product_price), 2) AS product_revenue_value,  
  ROUND(SUM(i.freight_value), 2) AS freight_total_value,
```

```


ROUND(SUM(i.item_gmv), 2) AS gmv_total_value,
ROUND(AVG(i.item_gmv), 2) AS avg_ticket_value
FROM main_catalog.gold.fact_order_item_sales i
LEFT JOIN main_catalog.gold.dim_product p
ON i.product_id = p.product_id
GROUP BY
COALESCE(p.product_category_name, 'not_available')
ORDER BY
product_revenue_value DESC
LIMIT 5;
'''

```

No recorte de categoria (Imagem 16), beleza_saude apresentou o maior GMV, com R\$ 1,44 milhão, seguida por relorios_presentes, com R\$ 1,31 milhão, e cama_mesa_banho, com R\$ 1,24 milhão. A categoria cama_mesa_banho registrou o maior número de pedidos entre as principais categorias, com 9.417 pedidos, enquanto beleza_saude registrou 8.836. Entre as categorias de maior valor por item, destacaram-se relorios_presentes, com ticket médio de R\$ 217,92, e moveis_escritorio, com R\$ 202,56.

IMAGEM 16 — Top 5 categorias por GMV

	analysis_group	analysis_level	order_count	item_count	product_revenue_value	freight_total_value	gmv_total_value	avg_ticket_value
1	beleza_saude	category	8836	9670	1258681.34	182566.73	1441248.07	149.04
2	relogios_presentes	category	5624	5991	1205005.68	100535.93	1305541.61	217.92
3	cama_mesa_banho	category	9417	11115	1036988.68	204693.04	1241681.72	111.71
4	esporte_lazer	category	7720	8641	988048.97	168607.51	1156656.48	133.86
5	informatica_acessorios	category	6689	7827	911954.32	147318.08	1059272.40	135.34



Fonte: A autora (2026).

A query utilizada em SQL por recorte de SELLERS foi:

```
%sql
```

```
...
```

```
SELECT
```

```
    i.seller_id AS analysis_group,
```

```
    'seller' AS analysis_level,
```

```
    COUNT(DISTINCT i.order_id) AS order_count,
```

```
    COUNT(*) AS item_count,
```

```
    ROUND(SUM(i.product_price), 2) AS product_revenue_value,
```

```
    ROUND(SUM(i.freight_value), 2) AS freight_total_value,
```

```
    ROUND(SUM(i.item_gmv), 2) AS gmv_total_value,
```

```
    ROUND(AVG(i.item_gmv), 2) AS avg_ticket_value
```

```
FROM main_catalog.gold.fact_order_item_sales i
```

```
GROUP BY
```

```
    i.seller_id
```

```
ORDER BY
```

```
    product_revenue_value DESC
```

LIMIT 5;

...

A concentração também ocorreu no nível de seller (Imagem 17). O seller "4869f7a5dfa277a7dca6462dcf3b52b2" liderou a receita de produtos na amostra analisada, com R\$ 229,47 mil em 1.132 pedidos. Outros sellers apresentaram ticket médio elevado, como "53243585a1d6dc2643021fd1853d8905", com R\$ 575,26, e "7e93a43ef30c4f03f38b393420bc753a", com R\$ 537,51. Esses sellers podem ter menor quantidade de pedidos que os líderes de volume, mas concentram transações de maior valor e exigem acompanhamento comercial e operacional individualizado.

IMAGEM 17 — Top 5 sellers

	A ⁰ analysis_group	A ⁰ analysis_level	Σ ⁰ order_count	Σ ⁰ item_count	.00 product_revenue_value	.00 freight_total_value	.00 gmv_total_val...	.00 avg_ticket_value
1	4869f7a5dfa277a7dca6462dcf3b52b2	seller	1132	1156	229472.63	20168.07	249640.70	215.95
2	53243585a1d6dc2643021fd1853d89...	seller	358	410	222776.05	13080.63	235856.68	575.26
3	4a3ca9315b744ce9f8e9374361493884	seller	1806	1987	200472.92	35067.04	235539.96	118.54
4	fa1c13f2614d7b5c4749cbc52fecda94	seller	585	586	194042.03	10042.70	204084.73	348.27
5	7c67e1448b00fe969d365cea6b010ab	seller	982	1364	187923.89	51612.55	239536.44	175.61

Fonte: A autora (2026).

A query utilizada em SQL pelo recorte de ESTADO DO CLIENTE foi:

%sql

...

SELECT

c.customer_state AS analysis_group,

'customer_state' AS analysis_level,

COUNT(DISTINCT f.order_id) AS order_count,

ROUND(SUM(f.product_total_value), 2) AS product_revenue_value,

ROUND(SUM(f.freight_total_value), 2) AS freight_total_value,

ROUND(SUM(f.gmv_total_value), 2) AS gmv_total_value,

ROUND(AVG(f.gmv_total_value), 2) AS avg_ticket_value

FROM main_catalog.gold.fact_order_service f

LEFT JOIN main_catalog.gold.dim_customer c

ON f.customer_unique_id = c.customer_unique_id

GROUP BY

c.customer_state


ORDER BY

```
product_revenue_value DESC;  
...
```

Aqui, o resultado demonstrou forte concentração comercial no estado de São Paulo, que registrou 41.746 pedidos, R\$ 5,20 milhões em receita de produtos, R\$ 718,8 mil em frete e R\$ 5,92 milhões em GMV. O ticket médio no estado foi de R\$ 143,13.

Rio de Janeiro e Minas Gerais ocuparam as posições seguintes em volume, com 12.856 e 11.629 pedidos, respectivamente. Entretanto, estados de menor volume apresentaram tickets médios mais elevados. A Paraíba registrou ticket médio de R\$ 264,97; o Acre, R\$ 242,84; o Amapá, R\$ 239,16; e Alagoas, R\$ 234,13. Esse resultado, mostrado na Imagem 18 abaixo, indica que a gestão comercial não deve considerar somente volume absoluto, pois localidades de menor escala podem concentrar pedidos de maior valor e maior exposição a frete.

IMAGEM 18 — Top 5 estados de cliente



Fonte: A autora (2026).

2.9.2 Pergunta 2 — Desempenho logístico

A segunda análise avaliou a taxa de entrega no prazo, o atraso médio, o prazo médio de entrega e a avaliação média por seller, categoria e estado do cliente. A taxa de entrega no prazo considera somente pedidos entregues e avaliáveis. A análise por seller e estado do cliente utiliza o grão de pedido; a análise por categoria utiliza o grão de item, pois um pedido pode conter produtos de mais de uma categoria.

A query utilizada em SQL por recorte de estado do cliente foi:

```
%sql
```

```
...
```

```
SELECT
  c.customer_state AS analysis_group,
  'customer_state' AS analysis_level,
  COUNT(DISTINCT f.order_id) AS delivered_order_count,
  ROUND(
    100.0 * AVG(
      CASE
        WHEN f.is_delivery_on_time = true THEN 1.0
        WHEN f.is_delivery_on_time = false THEN 0.0
        ELSE NULL
      END
    ),
    2
  ) AS on_time_delivery_rate_pct,
  ROUND(AVG(f.delivery_delay_days), 2) AS avg_delay_days,
  ROUND(AVG(f.actual_delivery_days), 2) AS avg_delivery_days,
  ROUND(AVG(f.review_score_avg), 2) AS avg_review_score
FROM main_catalog.gold.fact_order_service f
LEFT JOIN main_catalog.gold.dim_customer c
  ON f.customer_unique_id = c.customer_unique_id
WHERE f.is_delivered = true
GROUP BY
  c.customer_state
HAVING COUNT(DISTINCT f.order_id) >= 20
ORDER BY
```

```
on_time_delivery_rate_pct ASC,  
delivered_order_count DESC  
LIMIT 5;  
...
```


Os resultados mostraram diferenças relevantes de desempenho logístico conforme a localização e o seller responsável pela entrega. São Paulo, que concentra o maior volume de pedidos, também apresentou desempenho logístico favorável: 94,11% das entregas ocorreram no prazo, o prazo médio foi de 8,76 dias, o atraso médio foi de 0,41 dia e a avaliação média foi de 4,25. Minas Gerais e Paraná também apresentaram desempenho consistente, com taxas de entrega no prazo de 94,39% e 95,00%, respectivamente.

Em contraste, Alagoas apresentou a menor taxa de entrega no prazo entre os estados analisados, de 76,07%, prazo médio de 24,54 dias, atraso médio de 2,21 dias e avaliação média de 3,86. Maranhão registrou 80,45% de entregas no prazo e avaliação média de 3,82.

Ceará, Sergipe, Bahia e Rio de Janeiro também apresentaram desempenho abaixo dos principais estados de referência. O Rio de Janeiro exige atenção especial porque combina 12.353 pedidos entregues — um volume elevado — com somente 86,52% de entregas no prazo, atraso médio de 1,73 dia e prazo médio de 15,31 dias.

IMAGEM 19 — Top 5 estados por desempenho

	analysis_group	analysis_level	delivered_order_count	on_time_delivery_rate_pct	avg_delay_days	avg_delivery_days	avg_review_score
1	AL	customer_state	398	76.13	2.21	24.51	3.87
2	MA	customer_state	720	80.42	1.95	21.54	3.83
3	PI	customer_state	476	84.03	1.96	19.46	3.99
4	CE	customer_state	1280	84.69	2.19	21.26	3.95
5	SE	customer_state	334	84.73	2.58	21.55	3.9



Fonte: A autora (2026).

A query utilizada em SQL por recorte de categorias foi:

```
%sql
```

```
'''
```

```
SELECT
```

```
    COALESCE(p.product_category_name, 'not_available') AS analysis_group,
```

```
    'category' AS analysis_level,
```

```
    COUNT(DISTINCT i.order_id) AS delivered_order_count,
```

```
    ROUND(
```

```
        100.0 * AVG(
```

```
            CASE
```

```
                WHEN i.is_delivery_on_time = true THEN 1.0
```

```
                WHEN i.is_delivery_on_time = false THEN 0.0
```

```
            ELSE NULL
```

```
        END
```

```
    ),
```

```
    2
```

```
) AS on_time_delivery_rate_pct,
```

```
    ROUND(AVG(i.seller_customer_distance_km), 2) AS avg_distance_km,
```

```

    ROUND(AVG(i.review_score_avg), 2) AS avg_review_score
FROM main_catalog.gold.fact_order_item_sales i
LEFT JOIN main_catalog.gold.dim_product p
    ON i.product_id = p.product_id
WHERE i.order_status = 'delivered'
GROUP BY
    COALESCE(p.product_category_name, 'not_available')
HAVING COUNT(DISTINCT i.order_id) >= 20
ORDER BY
    on_time_delivery_rate_pct ASC,
    delivered_order_count DESC
LIMIT 5;
'''

```

No recorte de categorias, as principais categorias comerciais apresentaram taxas de entrega no prazo entre 90,95% e 93,25%. Apesar de não serem necessariamente as piores em entrega no prazo, algumas categorias relevantes tiveram avaliação média abaixo de 4, como moveis_escritorio (3,51), cama_mesa_banho (3,93), moveis_decoracao (3,96), informatica_acessorios (3,99) e telefonia (3,99). Esses resultados indicam a necessidade de investigar fatores adicionais de experiência, como integridade do produto, expectativa do cliente, frete e qualidade do atendimento.

A análise por categoria possui uma limitação analítica documentada. A tabela fact_order_item_sales está no grão de item e contém categoria, indicador de entrega no prazo e avaliação associada ao pedido. Ela permite calcular, por categoria, quantidade de pedidos entregues, taxa de entrega no prazo e avaliação média.

Entretanto, actual_delivery_days e delivery_delay_days estão armazenados na fact_order_service, cujo grão é pedido. Como um pedido pode conter itens de categorias diferentes, uma junção direta replicaria métricas de prazo e atraso para múltiplas categorias, podendo distorcer os indicadores. Para preservar o grão correto, o MVP apresenta prazo médio e atraso médio por seller e por estado, enquanto o recorte por categoria fica limitado à taxa de entrega no prazo e à avaliação média.

IMAGEM 20 — Top 5 categorias por desempenho

	A ₀ analysis_group	A ₀ analysis_level	A ₂ delivered_order_count	A ₀ on_time_delivery_rate_pct	A ₂ avg_distance_km	A ₂ avg_review_score
1	casa_conforto_2	category	24	83.33	478.29	3.63
2	moveis_colchao_e_estofado	category	37	86.49	266.4	3.91
3	audio	category	348	87.29	556.01	3.84
4	fashion_underwear_e_moda_pr...	category	117	87.40	548.51	4
5	artigos_de_natal	category	125	88.00	723.06	4.07

Fonte: A autora (2026).

A query utilizada em SQL por recorte de sellers foi:

```
%sql
```

```
...
```

```
SELECT
```

```
    l.seller_id AS analysis_group,
```

```
    'seller' AS analysis_level,
```

```
    l.delivered_order_count,
```

```
    ROUND(100.0 - l.late_delivery_rate_pct, 2) AS on_time_delivery_rate_pct,
```

```
    ROUND(l.avg_delay_days, 2) AS avg_delay_days,
```

```
    ROUND(l.avg_delivery_days, 2) AS avg_delivery_days,
```

```
    ROUND(l.avg_review_score, 2) AS avg_review_score
```

```
FROM main_catalog.gold.mart_logistics_performance l
```

```
WHERE l.delivered_order_count >= 20
```

```
ORDER BY
```

```
    on_time_delivery_rate_pct ASC,
```

```
    l.delivered_order_count DESC
```

```
LIMIT 5;
```

```
...
```

No nível de seller, observou-se heterogeneidade operacional significativa. Entre sellers com pelo menos 20 pedidos entregues, "f76a3b1349b6df1ee875d1f3fa4340f0" apresentou apenas 60,87% de entregas no prazo, seguido por "821fb029fc6e495ca4f08a35d51e53a5" com 62,50%, "ede0c03645598cdfc63ca8237acbe73d" com 65,12% e "ad781527c93d00d89a11eecd9dcad7c1" com 65,71%. Também foram observados atrasos médios severos, como 12,58 dias para o seller

"2a1348e9addc1af5aaa619b1a3679d6b" e 10,72 dias para "054694fa03fe82cec4b7551487331d74".

IMAGEM 21 — Top 5 sellers por desempenho

	analysis_group	analysis_level	delivered_order_count	on_time_delivery_rate_pct	avg_delay_days	avg_delivery_days	avg_review_score
1	f76a3b1349b6df1ee875d1f3fa4340f0	seller	24	62.5	2.89	17.02	3.46
2	821fb029fcb6e495ca4f08a35d51e53a5	seller	24	62.5	2.86	16.79	3.48
3	ede0c03645598cdfc63ca8237acbe73d	seller	43	65.12	3.6	18.59	3.57
4	ad781527c93d00d89a11eecd9dcad7...	seller	35	65.71	4.56	27.36	3.31
5	835f0f7810c76831d6c7d24c7a646d4d	seller	42	69.05	1.45	18.1	3.36

Fonte: A autora (2026).

2.9.3 Pergunta 3 — Relação entre atraso e satisfação

A terceira análise comparou pedidos entregues no prazo com pedidos entregues após a data estimada. Esse é o principal teste da associação entre confiabilidade logística e experiência pós-venda. A comparação é realizada somente para pedidos entregues e com avaliação disponível. São comparadas a avaliação média, a proporção de avaliações baixas e o volume de pedidos entre entregas no prazo e entregas atrasadas.

A query utilizada em SQL foi:

```
%sql
```

```
---
```

```
SELECT
```

```
  CASE
```

```
    WHEN is_delivery_late = true THEN 'late'
```

```
    WHEN is_delivery_on_time = true THEN 'on_time'
```

```
    ELSE 'not_evaluated'
```

```
  END AS delivery_status,
```

```
  COUNT(DISTINCT order_id) AS delivered_order_count,
```

```
  ROUND(AVG(actual_delivery_days), 2) AS avg_delivery_days,
```

```
  ROUND(AVG(delivery_delay_days), 2) AS avg_delay_days,
```

```
  ROUND(AVG(review_score_avg), 2) AS avg_review_score,
```

```
  ROUND(
```

```

100.0 * AVG(
    CASE
        WHEN review_score_avg <= 2 THEN 1.0
        WHEN review_score_avg IS NOT NULL THEN 0.0
        ELSE NULL
    END
),
2
) AS low_review_rate_pct
FROM main_catalog.gold.fact_order_service
WHERE
    is_delivered = true
    AND review_score_avg IS NOT NULL
    AND is_delivery_late IS NOT NULL
GROUP BY
    CASE
        WHEN is_delivery_late = true THEN 'late'
        WHEN is_delivery_on_time = true THEN 'on_time'
        ELSE 'not_evaluated'
    END
ORDER BY delivery_status;
'''

```


Os pedidos entregues com atraso totalizaram 7.613 ocorrências. Eles apresentaram prazo médio de entrega de 31,38 dias, atraso médio de 9,45 dias, avaliação média de 2,57 e taxa de avaliações baixas de 54,00%. Em contraste, os 87.751 pedidos entregues no prazo tiveram prazo médio de 10,87 dias, atraso médio nulo, avaliação média de 4,39 e apenas 3,16% de avaliações baixas.

A avaliação média de pedidos atrasados foi 1,82 ponto inferior à dos pedidos entregues no prazo. Além disso, a taxa de avaliações baixas em pedidos atrasados foi aproximadamente 17 vezes maior: 54,00% contra 3,16%.

Os resultados indicam uma associação forte entre atraso e deterioração da experiência do cliente. Embora o recorte observacional não permita afirmar que o

atraso seja a única causa de avaliações baixas, a diferença conjunta de prazo, avaliação média e incidência de avaliações negativas evidencia que reduzir atrasos deve ser uma prioridade operacional.

IMAGEM 22 — Comparação entre pedidos entregues no prazo e com atraso



Fonte: A autora (2026).

2.9.4 Pergunta 4 — Distância, frete e logística

A quarta análise avaliou a relação entre distância aproximada entre seller e cliente, valor de frete, prazo de entrega, atraso e avaliação. Foram considerados pedidos entregues com apenas um seller, pois a distância disponível na fato de serviço representa a relação entre o cliente e o seller de referência. As métricas são avaliadas por faixa de distância aproximada.

A query utilizada em SQL foi:

```
%sql
...

SELECT
    distance_band,
    COUNT(DISTINCT order_id) AS delivered_order_count,
    ROUND(AVG(seller_customer_distance_km), 2) AS avg_distance_km,
```

```

ROUND(AVG(freight_total_value), 2) AS avg_freight_value,
ROUND(AVG(actual_delivery_days), 2) AS avg_delivery_days,
ROUND(AVG(delivery_delay_days), 2) AS avg_delay_days,
ROUND(
    100.0 * AVG(
        CASE
            WHEN is_delivery_late = true THEN 1.0
            WHEN is_delivery_late = false THEN 0.0
            ELSE NULL
        END
    ),
    2
) AS late_delivery_rate_pct,
ROUND(AVG(review_score_avg), 2) AS avg_review_score
FROM main_catalog.gold.fact_order_service
WHERE
    is_delivered = true
    AND seller_count = 1
    AND distance_band <> 'not_available'
GROUP BY distance_band
ORDER BY
    CASE distance_band
        WHEN 'under_100_km' THEN 1
        WHEN '100_to_499_km' THEN 2
        WHEN '500_to_999_km' THEN 3
        WHEN '1000_to_1999_km' THEN 4
        WHEN '2000_km_or_more' THEN 5
        ELSE 6
    END;
...

```


Os resultados apontaram uma associação progressiva entre distância e piora dos indicadores logísticos. Em pedidos com distância inferior a 100 km, a distância média foi de 40,02 km, o frete médio foi de R\$ 13,26, o prazo médio foi de 6,52 dias,

o atraso médio foi de 0,38 dia, a taxa de atraso foi de 6,45% e a avaliação média foi de 4,29.

Na faixa de 2.000 km ou mais, a distância média chegou a 2.315,82 km, o frete médio subiu para R\$ 39,51, o prazo médio alcançou 21,21 dias, o atraso médio foi de 1,69 dia, a taxa de atraso chegou a 13,71% e a avaliação média caiu para 3,99. Em comparação com a faixa inferior a 100 km, essa faixa mais distante apresentou frete médio praticamente três vezes maior, prazo médio mais de três vezes superior e taxa de atraso mais que o dobro.

Esses resultados não demonstram causalidade isolada, mas revelam um padrão operacional consistente: rotas mais longas estão associadas a maior custo de frete, prazos maiores, maior exposição a atrasos e menor satisfação média. O resultado reforça a importância de revisar cobertura regional, SLAs logísticos, políticas de frete e possibilidades de aproximação entre estoque, sellers e clientes nas faixas de distância superiores a 1.000 km.

IMAGEM 23 — Evolução do frete médio e do prazo médio de entrega por faixa de distância aproximada entre seller e cliente



Fonte: A autora (2026).

2.9.5 Pergunta 5 — Priorização de sellers e categorias

A quinta análise integrou receita, volume, confiabilidade logística e satisfação para identificar sellers e categorias prioritários. Foram considerados prioritários os segmentos que combinam relevância comercial com sinais de risco, como atraso acima da referência e avaliação abaixo da referência.

Para sellers, a análise utiliza a mart logística, que contém receita de pedidos entregues, taxa de atraso e avaliação. Para categorias, a fato de itens permite medir receita, taxa de entrega no prazo e avaliação, mas não possui prazo ou atraso médio no grão de categoria.

A query utilizada em SQL por recorte de SELLERS foi:

```
%sql
```

```
...
```

```
WITH seller_metrics AS (
```

```
  SELECT
```

```
    seller_id,
```

```
    delivered_order_count,
```

```
    gmv_total_value,
```

```
    late_delivery_rate_pct,
```

```
    avg_delivery_days,
```

```
    avg_delay_days,
```

```
    avg_review_score,
```

```
    low_review_rate_pct,
```

```
    PERCENTILE_APPROX(gmv_total_value, 0.75) OVER () AS p75_gmv,
```

```
    AVG(late_delivery_rate_pct) OVER () AS overall_late_rate,
```

```
    AVG(avg_review_score) OVER () AS overall_review_score
```

```
  FROM main_catalog.gold.mart_logistics_performance
```

```
  WHERE delivered_order_count >= 20
```

```
)
```

```
SELECT
```

```
  seller_id,
```

```
  delivered_order_count,
```

```
  ROUND(gmv_total_value, 2) AS gmv_total_value,
```

```
  ROUND(late_delivery_rate_pct, 2) AS late_delivery_rate_pct,
```

```

ROUND(avg_delivery_days, 2) AS avg_delivery_days,
ROUND(avg_delay_days, 2) AS avg_delay_days,
ROUND(avg_review_score, 2) AS avg_review_score,
ROUND(low_review_rate_pct, 2) AS low_review_rate_pct
FROM seller_metrics
WHERE
    gmv_total_value >= p75_gmv
    AND late_delivery_rate_pct > overall_late_rate
    AND avg_review_score < overall_review_score
ORDER BY
    gmv_total_value DESC,
    late_delivery_rate_pct DESC,
    avg_review_score ASC
LIMIT 5;
...

```

No nível de seller, o seller 7c67e1448b00f6e969d365cea6b010ab deve ser priorizado por combinar R\$ 237,94 mil em GMV, 968 pedidos entregues, prazo médio de 22,42 dias, taxa de atraso de 10,12%, avaliação média de 3,50 e 25,00% de avaliações baixas. O seller 4a3ca9315b744ce9f8e9374361493884 apresentou R\$ 234,62 mil em GMV e 1.724 pedidos entregues, com taxa de atraso de 11,19% e avaliação média de 3,89. Ambos possuem relevância financeira e sinais consistentes de risco de experiência.

Também foram identificados sellers com risco operacional severo, ainda que com menor GMV. O seller 712e6ed8aa4aa1fa65dab41fed5737e4 apresentou taxa de atraso de 22,08%, prazo médio de 24,69 dias, atraso médio de 4,46 dias, avaliação média de 3,39 e 35,06% de avaliações baixas. O seller 2eb70248d66e0e3ef83659f71b244378 apresentou avaliação média de 2,79 e taxa de avaliações baixas de 46,77%. Esses casos devem ser priorizados para investigação de capacidade operacional, prazo prometido, expedição, transportadoras e atendimento pós-venda.

IMAGEM 24 — Top 5 sellers prioritários



Fonte: A autora (2026).

A query utilizada em SQL por recorte de CATEGORIAS foi:

```
%sql
```

```
...
```

```
WITH category_metrics AS (
```

```
    SELECT
```

```
        COALESCE(p.product_category_name, 'not_available') AS
```

```
product_category_name,
```

```
        COUNT(DISTINCT i.order_id) AS order_count,
```

```
        SUM(i.item_gmv) AS gmw_total_value,
```

```
        100.0 * AVG(
```

```
            CASE
```

```
                WHEN i.is_delivery_late = true THEN 1.0
```

```
                WHEN i.is_delivery_late = false THEN 0.0
```

```
            ELSE NULL
```

```
        END
```

```
    ) AS late_delivery_rate_pct,
```

```
        AVG(i.review_score_avg) AS avg_review_score,
```

```
        100.0 * AVG(
```

```

CASE
    WHEN i.review_score_avg <= 2 THEN 1.0
    WHEN i.review_score_avg IS NOT NULL THEN 0.0
    ELSE NULL
END
) AS low_review_rate_pct
FROM main_catalog.gold.fact_order_item_sales i
LEFT JOIN main_catalog.gold.dim_product p
    ON i.product_id = p.product_id
GROUP BY
    COALESCE(p.product_category_name, 'not_available')
HAVING COUNT(DISTINCT i.order_id) >= 20
),
benchmarks AS (
    SELECT
        PERCENTILE_APPROX(gmv_total_value, 0.75) AS p75_gmv,
        AVG(late_delivery_rate_pct) AS overall_late_rate,
        AVG(avg_review_score) AS overall_review_score
    FROM category_metrics
)
SELECT
    c.product_category_name,
    c.order_count,
    ROUND(c.gmv_total_value, 2) AS gmv_total_value,
    ROUND(c.late_delivery_rate_pct, 2) AS late_delivery_rate_pct,
    ROUND(c.avg_review_score, 2) AS avg_review_score,
    ROUND(c.low_review_rate_pct, 2) AS low_review_rate_pct
FROM category_metrics c
CROSS JOIN benchmarks b
WHERE
    c.gmv_total_value >= b.p75_gmv
    AND c.late_delivery_rate_pct > b.overall_late_rate
    AND c.avg_review_score < b.overall_review_score

```

ORDER BY

```
c.gmv_total_value DESC,  
c.late_delivery_rate_pct DESC,  
c.avg_review_score ASC
```

LIMIT 5

...

No nível de categoria, foram identificadas como prioritárias relorios_presentes, cama_mesa_banho, informatica_acessorios, moveis_decoracao e bebes. A categoria cama_mesa_banho merece atenção por reunir 9.417 pedidos e R\$ 1,24 milhão em GMV, com taxa de atraso de 8,40%, avaliação média de 3,90 e 18,68% de avaliações baixas. E moveis_decoracao apresentou R\$ 902,5 mil em GMV, taxa de atraso de 8,43% e 19,24% de avaliações baixas.

IMAGEM 25 — Top 5 categorias prioritárias

	product_category_name	order_count	gmv_total_value	late_delivery_rate_pct	avg_review_score	low_review_rate_pct
1	relorios_presentes	5624	1305541.61	8.28	4.02	16.25
2	cama_mesa_banho	9417	1241681.72	8.40	3.9	18.68
3	informatica_acessorios	6689	1059272.40	7.77	3.94	18.43
4	moveis_decoracao	6449	902511.79	8.43	3.91	19.24
5	bebes	2885	480118.00	8.79	4.01	16.76

Fonte: A autora (2026).

A análise de dados demonstrou que o MVP atende ao objetivo de integrar desempenho comercial e confiabilidade logística em uma visão única do ciclo de vendas digitais e marketplace. A camada Gold permitiu relacionar pedidos, itens, receita, frete, seller, localização, entrega e avaliação sem depender de consultas manuais a múltiplas tabelas operacionais. Em síntese, o Lakehouse deixa de fornecer somente indicadores isolados de faturamento e volume e passa a oferecer uma base analítica rastreável para decisões que equilibram crescimento comercial, eficiência logística e experiência do cliente.

2.10 LIMITAÇÕES DO PIPELINE

O pipeline desenvolvido constitui um MVP analítico e, portanto, possui limitações de escopo, atualização e interpretação. A solução foi construída sobre um conjunto público, histórico e anonimizado de pedidos do marketplace Olist, com aproximadamente 100 mil pedidos realizados entre 2016 e 2018.

Dessa forma, os resultados representam o comportamento observado nesse período e não devem ser interpretados como retrato atualizado da operação de e-commerce brasileira ou de uma empresa em produção.

Do ponto de vista operacional, a ingestão foi executada a partir de arquivos CSV disponibilizados para o projeto. Embora a arquitetura Bronze, Silver e Gold preserve rastreabilidade, quarentena e regras de qualidade, o fluxo não está conectado a fontes transacionais em tempo real, APIs, eventos de checkout ou atualizações contínuas. Em um cenário produtivo, seria necessário implementar orquestração agendada ou orientada a eventos, controle incremental de alterações, monitoramento de SLA/freshness, alertas automáticos de falha e mecanismos de reprocessamento.

Também existem limitações de granularidade no modelo analítico. A tabela `fact_order_service` está no grão de pedido e concentra métricas de prazo, atraso e avaliação, enquanto `fact_order_item_sales` está no grão de item e concentra categoria, preço, frete e GMV por item.

Como um pedido pode conter múltiplos itens, produtos, categorias e sellers, não é apropriado combinar diretamente métricas de pedido e item sem uma regra explícita de alocação. Por esse motivo, prazo médio e atraso médio foram analisados com segurança por pedido, seller e estado do cliente, mas não foram atribuídos diretamente a categorias, evitando duplicação de métricas e conclusões distorcidas.

A distância entre seller e cliente é uma estimativa geográfica, calculada a partir de coordenadas aproximadas associadas aos prefixos de CEP. Ela não representa a rota efetivamente percorrida, a malha logística, o modal de transporte, condições de tráfego, disponibilidade de estoque, transportadora contratada ou tentativas de entrega. Portanto, a associação observada entre distância, frete, prazo e atraso deve ser interpretada como evidência exploratória de cobertura logística, e não como medição exata do custo ou tempo de transporte.

As avaliações também possuem limitações interpretativas. Nem todos os pedidos possuem avaliação registrada, e uma nota baixa pode refletir diversos fatores

além da entrega, como qualidade do produto, expectativa do cliente, embalagem, atendimento, preço ou problemas de pagamento.

Assim, a análise identifica associação entre atrasos e avaliações menores, mas não comprova causalidade exclusiva. Da mesma forma, sellers e categorias classificados como prioritários devem ser tratados como pontos de investigação e monitoramento, não como evidência definitiva de responsabilidade individual.

Por fim, o dataset utiliza identificadores anonimizados e possui informações limitadas sobre operação interna, como custos reais de transporte, margem, estoque, campanhas, devoluções, cancelamentos detalhados, transportadoras, motivos de atraso e interações de atendimento.

Em uma evolução futura, a inclusão dessas fontes permitiria análises mais completas de rentabilidade, causa-raiz de atrasos, desempenho de parceiros logísticos, retenção de clientes e impacto financeiro da experiência pós-venda.

2.11 PRINCIPAIS APRENDIZADOS

O desenvolvimento deste MVP proporcionou uma visão prática e integrada do ciclo de Engenharia de Dados, desde a compreensão do problema de negócio até a disponibilização de dados confiáveis para análise. O principal aprendizado foi reconhecer que um projeto de dados não se resume à execução de consultas ou à criação de tabelas: ele exige decisões consistentes sobre origem, qualidade, transformação, modelagem, documentação, rastreabilidade e consumo analítico.

A construção da arquitetura Lakehouse reforçou a importância de organizar os dados em camadas com responsabilidades bem definidas. A camada Bronze preservou os dados de origem e seus metadados de ingestão; a camada Silver concentrou limpeza, padronização, validação e quarentena de registros inválidos; e a camada Gold estruturou fatos, dimensões e marts voltados ao consumo de negócio. Esse processo evidenciou que separar dados brutos, tratados e analíticos reduz riscos de perda de informação, melhora a auditabilidade e torna a solução mais sustentável para evoluções futuras.

Outro aprendizado relevante foi a importância do grão dos dados. Durante a modelagem e a análise, tornou-se necessário distinguir métricas no nível de pedido das métricas no nível de item. A tabela de serviço foi construída no grão de pedido,

concentrando prazo, atraso, avaliação e pagamento, enquanto a tabela de vendas foi construída no grão de item, concentrando produto, categoria, preço e frete por item. Compreender essa diferença foi essencial para evitar duplicação de valores financeiros e interpretações incorretas ao combinar tabelas.

A etapa de qualidade demonstrou que dados utilizáveis não são apenas dados sem valores nulos. Foi necessário definir campos críticos, validar domínios, verificar unicidade, testar integridade referencial, documentar exceções esperadas e preservar registros inválidos em quarentena.

A implementação de critérios de aceite e metadados de rastreabilidade mostrou como a Engenharia de Dados contribui para a confiança dos usuários nos indicadores finais, tornando possível identificar origem, processamento e contexto de cada ativo analítico.

O projeto também fortaleceu habilidades de SQL analítico e modelagem dimensional. A elaboração das perguntas de negócio exigiu selecionar a tabela correta para cada métrica, aplicar agregações sem violar o grão do modelo, utilizar dimensões para fornecer contexto e interpretar os resultados com cautela.

Além disso, a criação de fatos, dimensões e marts evidenciou como um modelo bem documentado reduz a complexidade das consultas e aproxima os dados das necessidades de gestores e analistas.

2.12 AUTOAVALIAÇÃO

Considero que alcancei o objetivo proposto para o MVP ao desenvolver uma solução que integra ingestão, tratamento, modelagem, validação de qualidade, análise e orquestração de dados. Minha contribuição não se limitou a executar notebooks: acompanhei a coerência entre o problema de negócio, as perguntas definidas, as tabelas construídas e as análises entregues. A execução bem-sucedida do Job com as etapas Bronze, Silver, Gold e qualidade representou um marco importante para verificar o funcionamento do fluxo completo também.

Meu principal avanço foi desenvolver uma postura mais crítica diante das decisões técnicas. Durante o projeto, precisei conferir os esquemas reais das tabelas, corrigir inconsistências entre nomes de colunas e consultas, respeitar a diferença

entre dados no nível de pedido e de item, e reconhecer quando uma métrica não podia ser atribuída com segurança a determinado recorte.

Também aprendi a não considerar uma execução sem erros como prova suficiente de qualidade: foi necessário definir critérios de validação, examinar os resultados e documentar as limitações da solução.

Assim, avalio meu desempenho como positivo, especialmente pela capacidade de revisar escolhas e ajustar o trabalho sem perder de vista o objetivo original do MVP. Ao mesmo tempo, reconheço que ainda preciso aprofundar minhas habilidades em automação contínua, ingestão incremental, monitoramento e tratamento de falhas em ambientes produtivos.

Encerro o projeto com maior autonomia para construir pipelines analíticos e, principalmente, com a compreensão de que uma boa solução de Engenharia de Dados precisa ser correta, rastreável, reproduzível e útil para quem toma decisões.

3. CONCLUSÃO

O desenvolvimento deste MVP demonstrou a viabilidade de aplicar uma arquitetura Lakehouse para transformar dados operacionais fragmentados de marketplace em uma base analítica integrada, rastreável e orientada à decisão.

A implementação das camadas Bronze, Silver e Gold permitiu preservar os dados de origem, aplicar regras de limpeza e qualidade, isolar registros inválidos em quarentena e disponibilizar fatos, dimensões e marts adequados ao consumo analítico. Esse fluxo seguiu o princípio da arquitetura medallion, na qual os dados evoluem progressivamente de registros brutos para estruturas validadas e enriquecidas para negócio.

Como resultado, o MVP atingiu seu objetivo de conectar desempenho comercial, confiabilidade logística e experiência do cliente em uma única visão analítica. A solução tornou possível relacionar pedido, item, produto, seller, frete, localização, prazo, atraso e avaliação, além de responder às questões prioritárias do negócio com dados validados e documentados.

Embora o projeto utilize dados históricos e possua limitações próprias de um ambiente acadêmico, ele estabelece uma fundação consistente para evoluções futuras, como ingestão incremental, monitoramento contínuo de qualidade e

atualidade, alertas para sellers ou regiões de risco, integração com novas fontes operacionais e dashboards executivos. A rastreabilidade construída também favorece auditoria e análise de impacto, práticas que podem ser ampliadas com mecanismos de linhagem e governança do Unity Catalog.

REFERÊNCIAS

CREATIVE COMMONS. Attribution-NonCommercial-ShareAlike 4.0 International: CC BY-NC-SA 4.0. [S. l.]: Creative Commons, [s. d.]. Disponível em: <https://creativecommons.org/licenses/by-nc-sa/4.0/>. Acesso em: 05 set. 2026.

DATABRICKS. Basic editing in Databricks notebooks. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/notebooks/basic-editing>. Acesso em: 12 set. 2026.

DATABRICKS. Clean and validate data on Databricks. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/transform/validate>. Acesso em: 12 set. 2026.

DATABRICKS. Configure task dependencies. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/jobs/run-if>. Acesso em: 19 set. 2026.

DATABRICKS. Connect your Git provider to Databricks. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/repos/get-access-tokens-from-git-provider>. Acesso em: 26 set. 2026.

DATABRICKS. Create and manage Git folders. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/repos/git-operations-with-repos>. Acesso em: 26 set. 2026.

DATABRICKS. Dimensional modeling in Lakeflow pipelines. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/ldp/best-practices/dimensional-modeling>. Acesso em: 12 set. 2026.

DATABRICKS. Import and export Databricks notebooks. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/notebooks/notebook-export-import>. Acesso em: 26 set. 2026.

DATABRICKS. Lakeflow Jobs. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/jobs/>. Acesso em: 19 set. 2026.

DATABRICKS. Lineage in Unity Catalog. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/data-governance/unity-catalog/data-lineage>. Acesso em: 12 set. 2026.

DATABRICKS. Visualizations in Databricks notebooks and SQL editor. Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/visualizations/>. Acesso em: 19 set. 2026.

DATABRICKS. What is the medallion lakehouse architecture? Databricks Documentation, 2026. Disponível em: <https://docs.databricks.com/aws/en/lakehouse/medallion>. Acesso em: 12 set. 2026.

OLIST. **Brazilian E-Commerce Public Dataset** by Olist. Kaggle, [s. d.]. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>. Acesso em: 05 set. 2026.